II.5. Predicația

Predicație (1)

- folosită în arhitectura Intel IA-64
 - și în alte unități de procesare
- asemănătoare cu execuția speculativă
- procesorul conține regiștri de predicate
 - predicat condiție booleană (bit)
- fiecare instrucțiune obișnuită are asociat un asemenea predicat

Predicație (2)

- o instrucțiune produce efecte dacă și numai dacă predicatul asociat este *true*
 - altfel rezultatul său nu este scris la destinație
- instrucțiunile de test pot modifica valorile predicatelor
- se pot implementa astfel ramificații în program

Exemplu

if(R1==0){
R2=5;
R3=8;

pseudocod

else

R2=21;

Exemplu (continuare)

• limbaj de asamblare "clasic"

```
cmp R1,0
jne E1
mov R2,5
mov R3,8
jmp E2
E1: mov R2,21
E2:
```

Exemplu (continuare)

• limbaj de asamblare cu predicate

```
cmp R1,0,P1
<P1>mov R2,5
<P1>mov R3,8
<P2>mov R2,21
```

- predicatele P1 și P2 lucrează în pereche
 - P2 este întotdeauna inversul lui P1
 - prima instrucţiune îi modifică pe amândoi

II.6. Execuţia out-of-order

Execuție out-of-order

- instrucțiunile nu se mai termină obligatoriu în ordinea în care și-au început execuția
- scop eliminarea unor blocaje în pipeline
- posibilă atunci când între instrucţiuni nu există dependenţe

Exemplu

```
in al,278
add bl,al
mov edx,[ebp+8]
```

- prima instrucțiune foarte lentă
- a doua instrucțiune trebuie să aștepte terminarea primeia
- a treia instrucțiune nu depinde de cele dinaintea sa - se poate termina înaintea lor

II.7. Redenumirea regiștrilor

Dependențe de date

- apar când două instrucțiuni folosesc aceeași resursă (variabilă/registru)
- numai când cel puţin una din instrucţiuni modifică resursa respectivă
- dacă resursele sunt regiştri, unele dependențe se pot rezolva prin redenumire

Tipuri de dependențe de date

- RAW (read after write)
 - prima instrucţiune modifică resursa, a doua o citeşte
- WAR (write after read)
 - invers
- WAW (write after write)
 - ambele instrucţiuni modifică resursa

Dependențe RAW

- dependențe "adevărate"
- nu pot fi eliminate

• valoarea scrisă în eax de prima instrucțiune este necesară instrucțiunii următoare

Dependențe WAR

• numite și antidependențe

• prima instrucțiune trebuie executată înaintea celei de-a doua (nu se poate în paralel)

Dependențe WAR - rezolvare

```
add esi,eax add esi,eax
mov eax,16 — mov reg_tmp,16
sub ebx,eax sub ebx,reg tmp
```

Dependențe WAW

• dependențe de ieșire

```
div ecx
sub ebx, edx
mov eax, 5
add ebp, eax
```

Dependențe WAW - rezolvare

```
div ecx, 3

sub ebx,edx sub ebx,edx

mov eax,5 mov reg_tmp,5

add ebp,eax add ebp,reg_tmp
```

Utilitate

- ajută la creșterea performanței?
- crește potențialul de paralelizare
- mai eficientă în combinație cu alte tehnici
 - structura superpipeline
 - execuţia out-of-order

Eficiența abordării

- mai mulţi regiştri
 - folosiţi intern de procesor
 - nu sunt accesibili programatorului
- de ce?
 - redenumirea se face automat
 - programatorul poate greşi (exploatare ineficientă a resurselor)
 - creșterea performanței programelor vechi

II.8. Hyperthreading

Hyperthreading (1)

- avem un singur procesor real, dar acesta apare ca două procesoare virtuale
- sunt duplicate componentele care reţin starea procesorului
 - regiştrii generali
 - regiştrii de control
 - regiștrii controllerului de întreruperi
 - regiștrii de stare ai procesorului

Hyperthreading (2)

- nu sunt duplicate resursele de execuție
 - unitățile de execuție
 - unitățile de predicție a salturilor
 - magistralele
 - unitatea de control a procesorului
- procesoarele virtuale execută instrucțiunile în mod întrepătruns

De ce hyperthreading?

- exploatează mai bine structura pipeline
 - când o instrucțiune a unui procesor virtual se blochează, celălalt procesor preia controlul
- nu oferă același câștig de performanță ca un al doilea procesor real
- dar complexitatea şi consumul sunt aproape aceleaşi cu ale unui singur procesor
 - componentele de stare sunt foarte puţine

II.9. Arhitectura RISC

Structura clasică a CPU

CISC (Complex Instruction Set Computer)

- număr mare de instrucțiuni
- complexitate mare a instrucţiunilor → timp mare de execuţie
- număr mic de regiştri → acces intensiv la memorie

Observații practice

- multe instrucțiuni sunt rar folosite
- 20% din instrucțiuni sunt executate 80% din timp
 - sau 10% sunt executate 90% din timp
 - depinde de sursa de documentare...
- instrucțiunile complexe pot fi simulate prin instrucțiuni simple

Structura alternativă

RISC (Reduced Instruction Set Computer)

- set de instrucțiuni simplificat
 - instrucţiuni mai puţine (relativ)
 - și mai simple funcțional (elementare)
- număr mare de regiștri (zeci)
- mai puţine moduri de adresare a memoriei

Accesele la memorie

- format fix al instrucţiunilor
 - același număr de octeți, chiar dacă nu toți sunt necesari în toate cazurile
 - mai simplu de decodificat
- arhitectură de tip *load/store*
 - accesul la memorie doar prin instrucţiuni de transfer între memorie şi regiştri
 - restul instrucţiunilor lucrează doar cu regiştri

Avantajele structurii RISC

- instrucțiuni mai rapide
- reduce numărul de accese la memorie
 - depinde de capacitatea compilatoarelor de a folosi regiştrii
- accesele la memorie mai simple
 - mai puţine blocaje în pipeline
- necesar de siliciu mai mic se pot integra circuite suplimentare (ex. cache)

II.10. Arhitecturi paralele de calcul

Calcul paralel - utilizare

- comunicare între aplicații
 - poate fi folosită și procesarea concurentă
- performanțe superioare
 - calcule ştiinţifice
 - volume foarte mari de date
 - modelare/simulare
 - meteorologie, astronomie etc.

Cum se obţine paralelismul?

- structuri pipeline
 - secvenţial/paralel
- sisteme multiprocesor
 - unitățile de calcul procesoare
- sisteme distribuite
 - unitățile de calcul calculatoare

Performanța

- ideal viteza variază liniar cu numărul de procesoare
- real un program nu poate fi paralelizat în întregime
- exemple
 - operații de I/O
 - sortare-interclasare

Scalabilitatea (1)

- creşterea performanţei o dată cu numărul procesoarelor
- probleme sisteme cu foarte multe procesoare
- factori de limitare
 - complexitatea conexiunilor
 - timpul pierdut pentru comunicare
 - natura secvenţială a aplicaţiilor

Scalabilitatea (2)

- funcțională pentru un număr relativ mic de procesoare
- număr relativ mare
 - creşterea de performanţă nu urmează creşterea numărului de procesoare
- număr foarte mare
 - performanţa se plafonează sau poate scădea

Sisteme de memorie

- după organizarea fizică a memoriei
 - centralizată
 - distribuită
- după tipul de acces la memorie
 - comună (partajată)
 - locală

Tipuri de sisteme multiprocesor

- sisteme cu memorie partajată centralizată
- sisteme cu memorie partajată distribuită
- sisteme cu schimb de mesaje

Memorie partajată centralizată

- denumiri
 - UMA (Uniform Memory Access)
 - SMP (Symmetrical Multiprocessing)
- memorie comună
- accesibilă tuturor procesoarelor
- timpul de acces la memorie
 - același pentru orice procesor și orice locație

Memorie partajată distribuită

- denumiri
 - DSM (Distributed Shared Memory)
 - NUMA (Non-Uniform Memory Access)
- memoria este distribuită fizic
- spaţiu de adrese unic
 - văzut de toate procesoarele
- accesul la memorie neuniform

Sisteme cu schimb de mesaje

- multicalculatoare
- fiecare procesor are propria memorie locală
 - nu este accesibilă celorlalte procesoare
- comunicarea între procesoare
 - transmiterea de mesaje explicite
 - similar reţelelor de calculatoare

Comunicare

- conectarea
 - între procesoare
 - între procesoare şi memorie
- variante
 - sisteme cu memorie partajată centralizată magistrală
 - sisteme cu memorie partajată distribuită reţele de interconectare

Comunicare pe magistrală

- economic
- proiectare simplă
- performanță mai redusă
- nu scalează bine cu numărul de procesoare
- rol important memoriile cache
 - probleme de coerență

Rețele de interconectare (1)

- între
 - procesoare
 - procesoare şi memorie
- scop
 - flexibilitate
 - performanţă
 - mai multe accese în paralel

Rețele de interconectare (2)

- tipuri de conectare
 - totală fiecare cu fiecare
 - parţială unele perechi de componente nu sunt conectate direct
- conectare procesoare-memorii
 - mai multe circuite de memorie
 - pot fi accesate în paralel de procesoare diferite

Coerența memoriei

- trebuie ca toate procesoarele să folosească ultima valoare scrisă pentru o variabilă partajată
- problema memoriile cache
- scopul orice variabilă partajată să aibă aceeași valoare
 - în toate cache-urile
 - în memoria principală

Coerența - cache write-back

x - variabilă partajată

Procesor	Acţiune	Valoare cache A	Valoare cache B	Valoare memorie
				9
A	i=x;	9		9
В	j=x;	9	9	9
A	x=5;	5	9	9
В	k=x;	5	9	9

Coerența - cache write-through

x - variabilă partajată

Procesor	Acţiune	Valoare cache A	Valoare cache B	Valoare memorie
				9
A	i=x;	9		9
В	j=x;	9	9	9
A	x=5;	5	9	5
В	k=x;	5	9	5

Ce înseamnă coerența? (1)

- 1. ordinea execuției
 - a) procesorul P scrie în variabila X
 - b) apoi procesorul P citește X
 - între a) şi b) nu există alte scrieri în X

→ citirea b) returnează valoarea scrisă de a)

Ce înseamnă coerența? (2)

- 2. viziune coerentă a memoriei
 - a) procesorul P scrie în variabila X
 - b) apoi procesorul Q (Q≠P) citește X
 - între a) şi b) nu există alte scrieri in X
 - între a) şi b) a trecut suficient timp
 - → citirea b) returnează valoarea scrisă de a)

Ce înseamnă coerența? (3)

- 3. serializarea scrierilor
 - a) procesorul P scrie în variabila X
 - b) procesorul Q (Q=P sau Q≠P) scrie în variabilaX

- → toate procesoarele văd cele două scrieri în aceeași ordine
- nu neapărat a) înaintea b)

Menţinerea coerenţei cache-urilor

- protocoale de menţinere a coerenţei
- se bazează pe informațiile despre liniile de cache
 - invalid datele nu sunt valide
 - dirty doar cache-ul curent deţine valoarea actualizată
 - shared cache-ul curent deţine valoarea actualizată, la fel memoria principală şi eventual alte cache-uri

Tipuri de protocoale

- directory based
 - informaţiile despre fiecare linie de cache ținute într-un singur loc
- snooping
 - fiecare cache are o copie a liniei partajate
 - fără centralizarea informației
 - cache-urile monitorizează magistrala
 - detectează schimbările produse în liniile de cache

Actualizarea cache-urilor

- fiecare cache anunță modificările făcute
- celelalte cache-uri reacționează
- contează doar operațiile de scriere
- variante
 - scriere cu invalidare (write invalidate)
 - scriere cu actualizare (write update)

Scriere cu invalidare (1)

- un procesor modifică o dată
- modificarea se face în cache-ul propriu
 - toate celelalte cache-uri sunt notificate
- celelalte cache-uri
 - nu au o copie a datei modificate nici o acțiune
 - au o copie a datei modificate își invalidează linia corespunzătoare
 - valoarea corectă va fi preluată când va fi nevoie

Scriere cu invalidare (2)

x - variabilă partajată

Proc.	Acţiune	Reacţie cache	Cache A	Cache B	Memorie
					9
A	i=x;	read miss	9		9
В	j=x;	read miss	9	9	9
A	x=5;	invalidation	5	inv.	9
В	k=x;	read miss	5	5	5

Scriere cu actualizare (1)

- un procesor modifică o dată
- modificarea se face în cache-ul propriu
 - toate celelalte cache-uri sunt notificate
 - se transmite noua valoare
- celelalte cache-uri
 - nu au o copie a datei modificate nici o acţiune
 - au o copie a datei modificate preiau noua valoare

Scriere cu actualizare (2)

x - variabilă partajată

Proc.	Acţiune	Reacţie cache	Cache A	Cache B	Memorie
					9
A	i=x;	read miss	9		9
В	j=x;	read miss	9	9	9
A	x=5;	invalidation	5	5	5
В	k=x;	read hit	5	5	5

Invalidare vs. actualizare (1)

- mai multe scrieri succesive în aceeași locație
 - write invalidation o singură invalidare (prima dată)
 - write update câte o actualizare pentru fiecare scriere
 - mai avantajos invalidare

Invalidare vs. actualizare (2)

- mai multe scrieri în aceeași linie de cache
 - modificarea unei locații necesită invalidarea/actualizarea întregii linii
 - write invalidation o singură invalidare (prima dată)
 - write update câte o actualizare pentru fiecare scriere
 - mai avantajos invalidare

Invalidare vs. actualizare (3)

- "timpul de răspuns"
 - timpul între modificarea unei valori la un procesor şi citirea noii valori la alt procesor
 - write invalidation întâi invalidare, apoi citire (când este necesar)
 - write update actualizare imediată
 - mai avantajos actualizare

Invalidare vs. actualizare (4)

- ambele variante au avantaje și dezavantaje
- scrierea cu invalidare ocupare (mult) mai redusă a memoriei și magistralelor
- scrierea cu actualizare rata de succes a cache-urilor mai mare
- mai des folosită invalidarea