

BAZE DE DATE

Proiectarea bazelor de date relaționale

Normalizare

Mihaela Elena Breabăn © FII 2015-2016

Normalizare

- Dependențe funcționale (revizitat)
- ► INF, 2NF, 3NF
- Forma normală Boyce-Codd (BCNF)
- Dependențe multivaluate (revizitat)
- Forma normala 4 (4NF)
- Denormalizare

Proiectarea schemei

- De obicei mai multe variante de proiectare
- Unele sunt (mult) mai bune decât altele
- Cum alegem?

- Teorie pentru proiectarea bazelor de date relaţionale cu fundamente în algebra relaţională, introdusă de Codd între '70-'74
 - Eliminarea anomaliilor la modificări în date
 - Minimizarea necesității reproiectării când sunt necesare extensii ale structurii
 - Evitarea avantajării anumitor interogări

Exemplu Schemă cu anomalii

- Informații cu privire la candidatii la admitere
 - CNP şi nume
 - Universitatea la care s-a candidat
 - Liceele de la care provin candidații (și orașele)
 - Hobby-urile candidaților

Candidati(CNP, aNume, uNume, liceu, loras, hobby)

Ioana cu CNP-ul 2810605222111 a studiat la Negruzzi în Iași, candidează la Cuza, Asachi și la Babes-Bolyai, îi place să joace tenis și să cânte la chitară

Câte tuple sunt necesare a fi inserate în relația Candidati pentru a păstra toate informațiile despre Ioana?

Anomalii de proiectare

- Redundanţă
- Anomalii de actualizare
- Anomalii la ştergere

Exemplu Schemă fără anomalii

- Informații cu privire la aplicațiile de admitere
 - CNP şi nume
 - Universitatea la care s-a candidat
 - Liceele de la care provin candidații (și orașele)
 - Hobby-urile candidaților

```
Absolvent(CNP, aNume)
Candidat(CNP, uNume)
Liceu(CNP, codLiceu)
LocatieLiceu(codLiceu, lNume, loraș)
Hobbies(CNP, hobby)
```

Informații cu privire la cursurile luate de studenti

- Studenții au id-uri unice și nume (nu sunt unice)
- Cursurile au număr de identificare unic și titlu (nu unic)
- Studenții iau un curs într-un anumit an și primesc o notă

Care e schema recomandată?

- Studiază(sID, nume,cID, titlu,an,notă)
- Curs(cID,titlu,an), Studiază(sID,cID,notă)
- Student(sID,nume), Curs(cID,titlu), Studiază(sID,cID,an,notă)
- Student(sID,nume), Curs(cID,titlu), Studiază(nume,titlu,an,notă)

Proiectarea prin descompunere

- Se pleacă de la "mega-relații" ce conțin tot
- Se descompune în relații mai mici ce păstrează toate informațiile
- Se poate realiza automat
 - Mega-relații + proprietăți ale datelor
 - Descompunerea se realizează pe baza proprietăților
 - Setul final de relaţii satisface anumite forme normale
 - Fără anomalii
 - ▶ Fără pierdere de informații

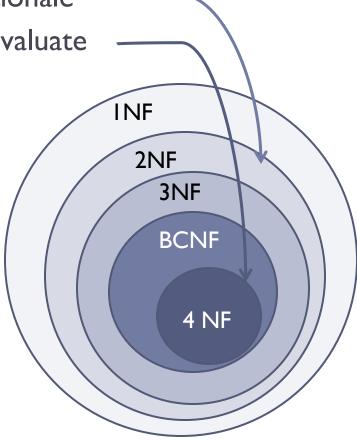
Proprietăți și forme normale

Proprietăți

Dependențe funcționale

Dependențe multivaluate

▶ Forme normale



Dependențe funcționale

Concepte folositoare pentru

- Stocarea datelor compresie
- Optimizarea interogărilor

$$X \rightarrow Y$$
 dacă
$$\forall t_1, t_2 \in r, t_1[X] = t_2[X] \Rightarrow t_1[Y] = t_2[Y]$$

r – relație peste mulțimea de atribute U X,Y – submulțimi ale lui U De ce funcțional?

Exemplu Dependențe funcționale

```
Absolvent(CNP, aNume, adresa,
lCod, lNume, lOras, medie,
prioritate)
Candidat(CNP, uNume, uOras, data,
specializare)
```

 Valorile atributului prioritate sunt determinate de valorile atributului medie

$$medie \rightarrow prioritate$$

Care sunt dependențele funcționale pentru relația Absolvent?

Dar pentru relația Candidat?

Ce constrângere este impusă de {CNP,uNume →data}

- ► R(A,B,C,D,E,F)
- ► ABC→D
- ▶ DE→F
- ► Fiecare din atributele A,B,C,E are cel mult 3 valori diferite.
- Care este numărul maxim de valori diferite pe care îl poate lua E? (3,9,27,81?)

Dependențe funcționale Reguli de inferență

- Reflexivitatea (FDI)
 - ► (AI)
 - dependențe triviale
- Descompunerea (FD6)
 - ► A(21)
 - Se poate descompune şi membrul stâng?
- Uniunea (FD5)
 - (A22)
- Tranzitivitatea (FD3)
 - (A3)
- Teorema de completitudine
 - o dependență funcțională este consecință a unei mulțimi de dependențe funcționale d.d. are demonstrație utilizând regulile de mai sus (Axiomele lui Armstrong)

Dependențe funcționale și chei

Dependențe funcționale (d.f.)

- Valorile unei submulțimi de atribute determină (identifică) valorile unei alte submulțimi de atribute
 - Formulate pe baza cunoașterii lumii reale
 - ▶ Toate instanțele relației trebuie sa le satisfacă
 - Se specifică un set minimal netrivial a.î. toate dependențele satisfăcute de relație se obțin ca și consecințe ale acestei mulțimi

Supercheie

- Valorile unei submulțimi de atribute identifică în mod unic un tuplu
 valorile tuturor atributelor
- O cheie este submulțime minimală cu proprietatea de mai sus
- Garantează o relație fără duplicate

Dependențele funcționale sunt o generalizare a noțiunii de cheie

Închideri

- Închiderea unei mulțimi de d.f. Σ notată Σ^+
 - Mulțimea d.f. Σ împreună cu toate d.f. consecințe din Σ
- Închiderea unei mulțimi de atribute X notată X^+ relativ la un set de d.f. Σ
 - Mulțimea tuturor atributelor B pentru care există $X \to B \in \Sigma^+$
- ▶ O dependență funcțională $X \to B$ este consecință a unei mulțimi de dependențe funcționale d.d. $B \in X^+$

Algoritm de calcul a închiderii lui X?

Închideri și chei

Date schema de relație R(U) și un set de d.f. Σ satisfăcute de R, submulțimea de atribute X este cheie pentru R d.d. $X^+ = U$ și $\forall X' \subset X, X'^+ \neq U$

Exemplu

Dată o mulțime de d.f. cum putem determina toate cheile?

555

- ► R(A,B,C,D,E)
- \rightarrow AB \rightarrow C
- ► AE→D
- \rightarrow D \rightarrow B
- ▶ Care sunt cheile pt. R?

Atribute (ne)prime

- Atribut prim
 - Există o cheie care să-l conțină
- Atribut neprim
 - Nu aparține nici unei chei
- Exemplu
 - ► RI(A, B, C, D)
 - $F = \{AB \rightarrow C, B \rightarrow D, BC \rightarrow A\}.$
 - ▶ AB si BC sunt singurele chei cu privire la F, deci A, B, C sunt atribute prime
 - Deste atribut neprim.

Dependențe pline

Fie dată o schemă de relatie R cu multimea de atribute U si F o multime de dependente functionale. O dependenta functionala X→ B ∈ F + (X⊂U, B ∈ U, B∉X) se numeste o dependenta plina a lui R (sau B este dependent plin de X sub F), daca nu exista nici o submultime proprie X'⊂X, astfel incat X' → B ∈ F+.

Exemplu

- ► *R*(*A*, *B*, *C*, *D*)
- $F = \{AB \rightarrow C, B \rightarrow D, BC \rightarrow A\}.$
- ▶ Toate dependențele din F sunt pline.
- ▶ $AB \rightarrow D \in F^+$ nu este dependență plină

Atribut tranzitiv dependent

- Fie R o schema cu multimea de atribute U si F o multime de dependente functionale. Un atribut B din U se numeste tranzitiv dependent de X (X⊂U, B∉X), daca exista Y⊂U, astfel incat:
 - ▶ B ∈ U-Y,
 - \rightarrow X \rightarrow Y \in F⁺,
 - $Y \rightarrow B \in F^+$
 - $Y \rightarrow X \notin F^+$.

O schemă de relație este în INF dacă domeniile de valori ale tuturor atributelor sunt elementare (indivizibile) deci diferite de multimi, de tuple de valori dintr-un anumit domeniu. În general numim valoare elementară o valoare pentru care în aplicații nu se utilizează părți ale ei

- O schema de relatie R situata in INF, impreuna cu o multime de dependente functionale F este in a doua forma normala daca orice atribut neprim din R este dependent plin de orice cheie a lui R.
- Dbs: Orice relație ce nu are chei multivaluate este în 2NF.
- Exemplu
 - ► *R*(*A*, *B*, *C*, *D*)
 - $F = \{AB \rightarrow C, B \rightarrow D, BC \rightarrow A\}.$
 - ▶ AB si BC sunt singurele chei
 - D este atribut neprim
 - ▶ B \rightarrow D \in F ⁺, deci D nu este dependent plin nici de AB, nici de BC. In concluzie, aceasta schema impreuna cu F nu este in 2NF.

- Absolventi(CNP, aNume, hobby)
- Un Absolvent, identificat prin CNP, are un singur nume însă mai multe hobbyuri
- Absolventi nu este în 2 NF. Ce anomalii apar din nerespectarea 2NF?
- Olimpici(concurs,an,CNP,nume)
- Intr-un anumit an există un singur câștigător (olimpic) la un anumit concurs. Câștigătorul e identificat prin CNP și are asociat un singur nume.
- Este Olimpici in 2NF?

Schema de relatie R impreuna cu multimea de dependente functionale F este in forma a treia normala (notata 3NF) daca este in a doua forma normala si orice atribut neprim din R NU este tranzitiv dependent de nici o cheie a lui R.

Exemplu

- ▶ *R*(*O*, *S*, *C*)
- $F = \{OS \rightarrow C, C \rightarrow O\}$
- OS si SC sunt chei.
- ▶ toate atributele sunt prime, deci schema este in 2NF si 3NF.

- Olimpici(concurs,an,CNP,nume)
- Intr-un anumit an există un singur câștigător (olimpic) la un anumit concurs. Câștigătorul e identificat prin CNP și are asociat un singur nume.
- Olimpici nu este in 3NF. Ce probleme de inconsistență a datelor pot să apară?

- Candidat(CNP,uNume,data,specializare)
- Un absolvent identificat prin CNP poate candida la orice universitate (identificata prin uNume) la o singură specializare din cadrul acesteia, deci o singura data
- Universitățile au date de aplicație care nu se suprapun
- Este Candidat în 3NF relativ la regulile specificate mai sus?

BCNF

- O schemă de relație R împreună cu o mulțime de dependențe funcționale F este în BCNF dacă este în INF și pentru orice dependență funcțională netrivială $X \rightarrow A \in F^+$ X este (super)cheie pentru R
- Orice schemă de relație în BCNF este în 3NF
 - Demonstrație?
- Proiectarea unei scheme de BD in BCNF are la bază descompunerea:
 - Intrare: o mega-relație împreună cu un set de dependențe funcționale
 - leşire: un set de relații în BCNF care în urma reasamblării produc informațiile originale

- Candidat(CNP,uNume,data,specializare)
- Un absolvent poate aplica la o universitate la o singură specializare
- Universitățile au date de aplicație care nu se suprapun
- Este Candidat în BCNF?

Descompunerea schemelor de relatie

- Fie schema de relatie $R[A_1, A_2, ..., A_n]$.
- $\rho = \{R_1, ..., R_k\}, \text{unde } R_i[A_{i1}, ..., A_{ihi}] \text{ este o descompunere a lui } R$ $\text{dacă} \bigcup_{i=1}^k \bigcup_{j=1}^{h_i} A_{ij} = \{A_n, ..., A_n\}$
- ▶ ρ este o descompunere de tip join fără pierdere a lui R cu privire la o mulțime de d.f. F, daca pentru orice relatie r peste R ce satisface F, avem $r = r[R_1] \bowtie ... \bowtie r[R_k]$ deci r se obține în urma joinului natural peste descompunerea ρ.

Exemplu Descompunere

- Absolvent(CNP,aNume,adresa,ICod,INume,IOras,medie, prioritate)
- ▶ $\rho_1 = \{S_1(CNP,aNume,adresa,\underline{ICod},medie,prioritate), S_2(\underline{ICod},INume,IOras)\}$
- $ρ_2 = {S_1(CNP, aNume, adresa, ICod, INume, IOras), S_2(aNume, INume, medie, prioritate)}$
- ρ1 de tip join fără pierdere
- ρ2 NU e de tip join fără pierdere

Descompuneri de tip join fără pierdere

Teoremă

Daca $\rho = (R_1, R_2)$ este o descompunere a lui R si F este o multime de d.f., atunci ρ este o descompunere join fara pierdere cu privire la F d.d. $R_1 \cap R_2 \rightarrow R_1 - R_2 \in F^+$ sau $R_1 \cap R_2 \rightarrow R_2 - R_1 \in F^+$.

(prin intersectia schemelor se intelege intersectia multimilor de atribute)

Exemplu

- ► R (A,B,C)
- $\vdash F = \{A \rightarrow B\}.$
- $\rho_1 = (R_1(A,B), R_2(A,C))$
- ▶ AB \cap AC = A, AB-AC = B,A \rightarrow B \in F⁺
- ρ_1 este de tip join fara pierdere
- $\rho_2 = (R_1(A,B), R_2(B,C)).$
- ▶ AB \cap BC = B, AB-BC = A, B \rightarrow A \notin F⁺,
- ▶ AB \cap BC = B, BC-AB = C, B \rightarrow C \notin F⁺,
- ρ_2 nu este de tip join fara pierdere cu privire la F.

Descompunere de tip join fara pierdere in BCNF

Intrare:

Schema de relatie R cu dependentele functionale F.

lesire:

Descompunerea $\rho = (R_1,...,R_k)$, astfel incat ρ este de tip join fara pierdere cu privire la F si (R_i,F_i) este in BCNF \forall i = I, k.

Pasul I.

- $\rho = R = R_1$
- ▶ Calculăm F⁺ și cheile necesare verificării formei BCNF

Pasul 2.

- Fie R_i o schema de relatie din ρ , pentru care (R_i, F_i) nu este in BCNF.
- ▶ Exista $X \rightarrow A \in F_i^+, A \notin X$ si X nu include o cheie.
- ► Construim $S_1 = X \cup \{A\}, S_2 = Ri -A$
- Înlocuim R_i in ρ prin S_1 , S_2 . k = k + 1.
- ► Calculăm $F_{S1}^+ F_{S2}^+$ și cheile pt. S_1 , S_2 necesare verificării formei BCNF

Pasul 3.

Repetam pasul 2, pana cand obtinem toate (R_i,F_i) , i=1,k in BCNF.

Exemplu Descompunere în BCNF

```
Absolvent(CNP, aNume, adresa,
           1Cod, 1Nume, 10ras, medie, prioritate)
CNP \rightarrow aNume, adresa, medie
medie → prioritate
1Cod \rightarrow 1Nume, 10ras
{R1(1Cod,1Nume,1Oras),
  R2(medie,prioritate),
  R3(CNP,aNume,adresa,medie),
  R4(CNP,1Cod)}
este o descompunere de tip join fără pierdere în
 BCNF
```

Pentru o schemă de relație R pot exista mai multe descompuneri de tip join fără pierdere în BCNF?

Garantează desc. în BCNF o schemă bună?

- ▶ Poate fi reconstruită relația originală?
- Elimină redundanța?
 - Candidat(CNP, uNume, hobby)
 - ▶ d.f.? NU
 - ▶ Chei? Toate atributele
 - ▶ BCNF? DA
 - ▶ Schemă bună? ...

Dependențe multivaluate

Reguli generatoare de tuple

$$X \to Y$$
 daca $\forall t_1, t_2 \in r, t_1[X] = t_2[X], \text{ exist a } t_3, t_4 \in r \text{ ast fel încât}$ (i) $t_3[X] = t_1[X], t_3[Y] = t_1[Y] \text{ și } t_3[Z] = t_2[Z]$ (ii) $t_4[X] = t_2[X], t_4[Y] = t_2[Y] \text{ și } t_4[Z] = t_1[Z]$

r – relație peste mulțimea de atribute U X,Y – submulțimi ale lui U Z=U-XY

Orice d.f. este d.mv.

Exemplu Dependențe multivaluate

- Candidat(CNP, uNume, hobby)
- Cerinţe:
 - Aceleaşi hobbyuri la toate univ
- Regula corespunzătoare:
 - ► CNP→→uNume

Exemplu extins

- Candidat(CNP, uNume, data, specializare, hobby)
- Cerinţe:
 - Hobbyurile sunt introduse selectiv în funcţie de universitate
 - Un Absolvent candidează într-o singură zi la o anumită universitate
 - Un Absolvent poate aplica la mai multe specializări (hobbyurile declarate la o univ. trebuie sa fie vizibile la specializarile de la acea univ.)
- Regulile corespunzătoare:
 - ► CNP, uNume→data
 - ► CNP, uNume, data→→specializare

- ► Fie R(A,B,C) și $A \rightarrow B$
- ▶ A ia cel puţin 3 valori diferite iar fiecare valoare a lui A este asociată cu cel puţin 4 valori diferite pentru B şi cel puţin 5 valori diferite pentru C.
- Care este numărul minim de tuple în R?

Dependențe multivaluate Reguli

- Dependențe triviale
 - Reflexivitate (MVDI)
 - $X \longrightarrow Y$ unde XY=U
- Complementariere (MVD0)
- Tranzitivitatea (!=d.f.)
- Intersecția

- O schemă de relație R și o mulțime de dependențe multivaluate D este în 4NF dacă este în 1NF și pentru orice dependență multivaluată netrivială $X \to A \in D^+$ X este (super)cheie pentru R
- Orice schemă de relație în 4NF este în BCNF
- Proiectarea unei scheme de BD in 4NF are la bază descompunerea:
 - Intrare: o mega-relație împreună cu un set de dependențe funcționale și multivaluate
 - leşire: un set de relații în 4NF care în urma reasamblării produc informațiile originale

Descompunere de tip join fara pierdere in 4NF

Intrare:

Schema de relatie R cu dependentele functionale F şi dependenţele multivaluate
 MV

lesire:

Descompunerea lui $\rho = (R_1,...,R_k)$, astfel incat ρ este de tip join fara pierdere cu privire la F si (R_i,F_i,MV_i) este in $4NF \forall i=1,k$.

Pasul I.

- $\rho = R = R_1$
- ► Calculăm M={F⁺,MV⁺} și cheile necesare verificării formei 4NF

Pasul 2.

- Fie R_i o schema de relatie din ρ , pentru care (R_i, F_i, MV_i) nu este in 4NF.
- Exista $X \rightarrow A \in M$ netrivială si X nu include o cheie.
- $Construim S_1 = X U \{A\}, S_2 = R_i -A$
- Înlocuim R_i in ρ prin S_1 , S_2 . k = k + 1.
- ► Calculăm d.mv și cheile pt. S₁, S₂ necesare verificării formei 4NF

Pasul 3.

Repetam pasul 2, pana cand obtinem toate (R_i,F_i) , i=1,k in NF.

Exemplu Descompunere în 4NF

- Candidat(CNP, uNume, hobby)
- ▶ CNP→→uNume
- $ρ = {A_1(CNP, uNume), A_2(CNP, hobby)}$ este descompunere în 4NF de tip join fără pierdere
- ▶ u*h, u+h

Exemplu extins

- Candidat(CNP, uNume, data, specializare, hobby)
- ► CNP, uNume → data
- ► CNP, uNume, data→→specializare
- ρ ={A₁(CNP, uNume, data),
 A₂(CNP, uNume, specializare),
 A₃(CNP, uNume, hobby)}

este în 4NF de tip join fără pierdere

Neajunsuri ale normalizării Exemplu 1

- Candidat(CNP,uNume,data,specializare)
- ▶ CNP,uNume→data,specializare
- ▶ data→uNume
- {A I (data,uNume), A2(CNP,data,specializare)} în 4NF este o schemă mai bună?

Neajunsuri ale normalizării Exemplu 2

- Absolvent(CNP,INume,medie,prioritate)
- ► CNP→medie
- ▶ medie →prioritate
- ► CNP → prioritate
- \{SI(CNP,prioritate),S2(CNP,medie),S3(CNP,INume)\} în 4NF este o schemă bună?

Neajunsuri ale normalizării

- Supra-descompunere
- ▶ Interogări supra-încărcate

▶ Ca soluție se poate aplica denormalizarea

Bibliografie

- Victor Felea: Baze de date relationale. Dependente. Editura Universitatii "Al.I.Cuza" lasi, 1996
- Hector Garcia-Molina, Jeff Ullman, Jennifer Widom: Database Systems: The Complete Book, Prentice Hall; 2nd edition (June 15, 2008)

 Unele exemple sunt adaptate dupa cursul public de Baze de date de la Stanford (autor Jennifer Widom)