


Midterm. Practical exercises

Total: 5p. Minimum: 1.25p

1. (0.3p+0.2p) A fair die is thrown twice. A is the event "sum of the throws equals 4", B is "at least one of the throws is a 3".

- Calculate $P(A|B)$.
- Are A and B independent events?

2. (0.2p+0.25p+0.25p) The cumulative distribution function of a discrete random variable is represented below.



If the random variable is called X and $P(X = 1)$ is stored in a code variable called p , what does the following code print? Justify your answers!

Code for E1, E2 groups	Code for E3, E4 groups
<pre>import tensorflow_probability as tfp tfd = tfp.distributions X = tfd.Bernoulli(probs=p) print(X.prob(0).numpy()) print(X.prob(1).numpy()) print(X.mean().numpy()) print(X.variance().numpy())</pre>	<pre>from scipy.stats import bernoulli print(bernoulli.pmf(0,p)) print(bernoulli.pmf(1,p)) print(bernoulli.mean(p)) print(bernoulli.var(p))</pre>

3. (0.3p) For the dataset below, you are trying to find the variable that is most helpful in predicting Y, according to information gain. Replace variables "a" to "n" with correct values in the code below such that it answers your question.

Code for E1, E2 groups	Code for E3, E4 groups
<pre>import pandas as pd data = pd.DataFrame([(0, 0, 1), (0, 0, 1), (1, 1, 1), (0, 1, 0), (1, 0, 0), (0, 1, 0), (0, 1, 0), (1, 0, 0)], columns=["X1", "X2", "Y"])</pre>	
<pre>import math import tensorflow_probability as tfp tfd = tfp.distributions def f_entropy(probs): X = tfd.Categorical(probs=probs) return X.entropy().numpy()/math.log(2)</pre>	<pre>from scipy.stats import entropy def f_entropy(probs_or_counts): return entropy(probs_or_counts, base=2)</pre>
<pre>H_y = f_entropy([a, b]) H_y_X1_0 = f_entropy([c, d]) # H(y X1=0) H_y_X1_1 = f_entropy([e, f]) # H(y X1=1) H_y_X2_0 = f_entropy([g, h]) # H(y X2=0) H_y_X2_1 = f_entropy([i, j]) # H(y X2=1) IG_X1_y = H_y - k*H_y_X1_0 - l*H_y_X1_1 # IG(y;X1) IG_X2_y = H_y - m*H_y_X2_0 - n*H_y_X2_1 # IG(y;X2) print(f"IG(X1;y)={IG_X1_y}") print(f"IG(X2;y)={IG_X2_y}")</pre>	

4-6. For the exercises from 4 to 6, consider the following code snippet. **Notice that there are TWO print statements at the end on the code.**

```
import pandas as pd
from sklearn import tree, naive_bayes, neighbors


features = ['A', 'B', 'C', 'Y']
data = pd.DataFrame([
    (0, 0, 0, 0),
    (0, 0, 1, 0),
    (0, 1, 0, 0),
    (0, 1, 1, 0),
    (1, 0, 0, 0),
    (1, 0, 1, 1),
    (1, 1, 0, 1)
],
columns=features)

X = data[['A', 'B', 'C']]
y = data['Y']

model = ...
model.fit(X,y)

new_instance = pd.DataFrame([
    (1, 1, 1)
],
columns=['A', 'B', 'C'])
print(model.predict(new_instance))
print(model.predict_proba(new_instance))
```

4. (0.8p+0.2p) Look at the following image to recall how the depth of a tree is computed.



What does the code above print if the line

```
model = ...
```

is replaced by

```
model = tree.DecisionTreeClassifier(criterion='entropy',max_depth=1)
```

? Justify your answer! You may use the fact that:

$H([0+,n-])=H([n+,0-])=0$, $H([1+,2-])=H([2+,1-])=0.9182$, $H([1+,3-])=H([3+,1-])=0.8112$.

5. (0.8p+0.2p) Recall that `alpha=1` in `BernoulliNB(alpha=1)` refers to the add-one Laplace smoothing rule. What does the code above print if the line

```
model = ...
```

is replaced by

```
model = naive_bayes.BernoulliNB(alpha=1)
```

? Justify your answer!

6. (0.8p+0.2p) What does the code above print if the line


```
model = ...
```

is replaced by

```
model = neighbors.KNeighborsClassifier(n_neighbors=3)
```

? Justify your answer!

7. (0.5p) For the following dataset, which algorithm works best (according to CVLOO)? Is it 1-NN, 3-NN or 5-NN? Justify your answer by calculating the error in each case (no need to create tables for each point)!



Teorie: 5p. Minim: 1.25

Învățare automată

— Licență, anul III, 2021-2022, examenul parțial I —

Nume student:

Grupa:


1. 1.5p

(Algoritmul k -NN, cu aplicare pe date din \mathbb{R}^2 , respectiv \mathbb{R} :
desenarea de diagrame Voronoi / identificarea zonelor de decizie;
calcularea erorii la CVLOO)

A. Se dă un set de date de antrenament din planul euclidian (\mathbb{R}^2), format din instanțele negative $(-1, 0)$, $(2, 1)$ și $(2, -2)$ și instanțele pozitive $(0, 0)$ și $(1, 0)$.

a. Pe reperul de axe de coordonate ortogonale alăturat marcați aceste exemple de antrenament. Veți folosi *convenția* noastră de notare: simbolul \bullet desemnează instanțe pozitive (+), iar simbolul \circ instanțe negative (-). Desenați apoi granițele de decizie determinate de algoritmul 1-NN. Veți hașura zona / zonele de decizie corespunzătoare instanțelor pozitive.

b. Cum va clasifica instanța de test $(1, -1.01)$ de către algoritmul 1-NN? Dar de către algoritmul 3-NN? Justificați, în ambele cazuri.



2. 3.5p

(Un exemplu de clasificator de tip bayesian care combină avantajele algoritmilor Bayes Naiv și Bayes Optimal)

Fie A, B și C variabile aleatoare binare independente, fiecare dintre ele având posibilitatea să ia valoarea 0 cu probabilitate de 50%. Considerăm funcția

$$Y = ((\neg B) \wedge (\neg C)) \vee (A \wedge B).$$

a. Scrieți *tabela de adevăr* a funcției Y .

b. i. Folosind tabela de adevăr a funcției Y — văzută acum ca un set de date de antrenament pentru un clasificator de tip bayesian — *estimați* valorile următoarelor probabilități condiționate:¹

$P(A = 0 B = 0, Y = 0) = \dots$	$P(A = 0 C = 0, B = 0, Y = 0) = \dots$ $P(A = 0 C = 1, B = 0, Y = 0) = \dots$
$P(A = 0 B = 0, Y = 1) = \dots$	$P(A = 0 C = 0, B = 0, Y = 1) = \dots$ $P(A = 0 C = 1, B = 0, Y = 1) = \dots$
$P(A = 0 B = 1, Y = 0) = \dots$	$P(A = 0 C = 0, B = 1, Y = 0) = \dots$ $P(A = 0 C = 1, B = 1, Y = 0) = \dots$
$P(A = 0 B = 1, Y = 1) = \dots$	$P(A = 0 C = 0, B = 1, Y = 1) = \dots$ $P(A = 0 C = 1, B = 1, Y = 1) = \dots$

Atenție! Unele dintre aceste probabilități condiționate s-ar putea să nu fie definite. De exemplu, $P(A = 0|C = 0, B = 0, Y = 0)$ este nedefinită, fiindcă $P(C = 0, B = 0, Y = 0) = 0$, adică (veți vedea) nu există în tabelul de date nicio combinație de forma $C = 0, B = 0, Y = 0$. În dreptul unor astfel de probabilități condiționate nedefinite veți pune semnul $*$ (*nedefinit*).

ii. Analizând rezultatele estimărilor obținute mai sus, se poate deduce o relație de tip *independență condițională* între variabilele A, B, C și Y . Care este această relație?

c. i. Pe baza rezultatului de la punctul b.ii, scrieți *regula de decizie* pe care o poate folosi un clasificator de tip bayesian — diferit de Bayes Naiv și Bayes Optimal / Comun; să-i spunem *New-Bayes* — pentru învățarea conceptului / funcției Y , astfel încât

- să producă eroare 0 pe setul de date [de antrenament] de la punctul a, dar
- să necesite un număr de parametri „liberi” (engl., free) care trebuie estimați mai mic decât cel al algoritmului Bayes Optimal.

ii. *Justificați* în mod riguros regula de decizie pe care ați scris-o și că eroarea la antrenare produsă de la punctul a este într-adevăr 0.

iii. Care sunt acești parametri „liberi”?

iv. *Comparați* numărul acestor parametri „liberi” cu numărul minimal de parametri necesari de estimat de către clasificatorii Bayes Naiv și respectiv Bayes Optimal pe același set de date.

¹Estimarea va fi făcută în mod clasic, adică în sensul verosimilității maxime (engl., Maximum Likelihood Estimation, MLE). Nu veți aplica nicio regulă de netezire a acestor probabilități, cum ar fi regula “add-one” a lui Laplace.