

# **Calcul Numeric**

**Cursul 7**

**2022**

*Anca Ignat*

## **Metode iterative pentru matrice simetrice și pozitiv definite**

Considerăm cazul sistemelor liniare cu matricea sistemului simetrică și pozitiv definită:

$$A = A^T \text{ – matrice simetrică – } a_{ij} = a_{ji} \quad \forall i, j = 1, 2, \dots, n$$

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{nn} \end{pmatrix} = A^T = \begin{pmatrix} a_{11} & a_{21} & a_{31} & \cdots & a_{n1} \\ a_{12} & a_{22} & a_{32} & \cdots & a_{n2} \\ a_{13} & a_{23} & a_{33} & \cdots & a_{n3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & a_{3n} & \cdots & a_{nn} \end{pmatrix}$$

$$A = A^T \quad \Rightarrow \quad A = L + D + L^T$$

$$D = \text{diag}[a_{11}, a_{22}, \dots, a_{nn}] = \begin{pmatrix} a_{11} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & a_{22} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & a_{nn} \end{pmatrix}$$

$$\begin{aligned}
L &= \begin{pmatrix} \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} \\ a_{21} & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} \\ a_{31} & a_{32} & \mathbf{0} & \cdots & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & \mathbf{0} \end{pmatrix} & L^T &= \begin{pmatrix} \mathbf{0} & a_{12} & a_{13} & \cdots & a_{1n} \\ \mathbf{0} & \mathbf{0} & a_{23} & \cdots & a_{2n} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & a_{n-1n} \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{0} \end{pmatrix}
\end{aligned}$$

## Definiții

Matricea  $A \in \mathbb{R}^{n \times n}$  se numește *pozitiv semidefinită* ( $A \geq 0$ ):

$$(Ax, x)_{\mathbb{R}^n} \geq 0 \quad \forall x \in \mathbb{R}^n.$$

Matricea  $A$  se numește *pozitiv definită* ( $A > 0$ ) dacă:

$$(Ax, x)_{\mathbb{R}^n} > 0 \quad \forall x \in \mathbb{R}^n, x \neq 0.$$

## Propoziție

Dacă matricea  $A \in \mathbb{R}^{n \times n}$  este pozitiv definită atunci matricea  $A$  este nesaringulară.

Demonstrație: Presupunem prin reducere la absurd că matricea  $A$  este pozitiv definită și singulară. Atunci, sistemul de ecuații liniare  $Ax=0$  are pe lângă soluția banală  $x=0$  și o soluție  $x^0 \neq 0$ . Avem:

$$x^0 \neq 0 \Rightarrow 0 < (Ax^0, x^0) = (0, x^0) = 0 \text{ contradicție!}$$

$$A > 0 \Rightarrow a_{ii} = (Ae_i, e_i) > 0 \quad \forall i = 1, \dots, n$$

### Lemă

Fie  $A \in \mathbb{R}^{n \times n}$  o matrice simetrică și  $B \in \mathbb{R}^{n \times n}$  o matrice nesară, astfel încât matricea  $P = B + B^T - A$  este pozitiv definită. Fie matricea  $M = I_n - B^{-1}A$ . Atunci raza spectrală a matricei  $M$  este strict subunitară dacă și numai dacă matricea  $A$  este pozitiv definită:

$$\rho(M) < 1 \Leftrightarrow A > 0$$

### Teoremă

Fie  $A \in \mathbb{R}^{n \times n}$  o matrice simetrică, nesară, cu diagonală pozitivă,  $a_{ii} > 0$ ,  $\forall i = 1, \dots, n$  și  $b \in \mathbb{R}^n$  vectorul termenilor liberi. Atunci metoda lui Gauss-Seidel generează șiruri convergente la soluția  $x^* = A^{-1}b$ ,  $\forall x^{(0)}$  dacă și numai dacă  $A$  este pozitiv definită.

Demonstrație: Din teorema de convergență avem:

$$\mathbf{x}^{(k)} \rightarrow \mathbf{x}^*, \quad k \rightarrow \infty \quad \Leftrightarrow \quad \rho(\mathbf{M}) < 1$$

Dacă matricea  $\mathbf{A}$  se scrie sub forma:

$$\mathbf{A} = \mathbf{L} + \mathbf{D} + \mathbf{L}^T$$

matricele  $\mathbf{B}$  și  $\mathbf{C}$  sunt date de:

$$\mathbf{B} = \mathbf{L} + \mathbf{D} \quad , \quad \mathbf{C} = \mathbf{B} - \mathbf{A} = -\mathbf{L}^T$$

Matricea iterației  $\mathbf{M}$  este:

$$\mathbf{M} = \mathbf{B}^{-1}\mathbf{C} = \mathbf{B}^{-1}(\mathbf{B} - \mathbf{A}) = \mathbf{I}_n - \mathbf{B}^{-1}\mathbf{A}$$



Încercăm să aplicăm **Lema** de mai sus. Pentru aceasta verificăm dacă matricea  $P$  este pozitiv definită:

$$P = B + B^T - A = L + D + (L + D)^T - L - D - L^T = D$$

$$(Px, x)_{\mathbb{R}^n} = (Dx, x)_{\mathbb{R}^n} = ((a_{ii}x_i)_i, (x_i)_i)_{\mathbb{R}^n} = \sum_{i=1}^n a_{ii}x_i^2$$

$$a_{ii} > 0 \quad \forall i \Rightarrow (Px, x)_{\mathbb{R}^n} > 0 \quad \forall x \in \mathbb{R}^n, x \neq 0 \Rightarrow P > 0$$

Putem aplica **Lema** de unde deducem convergența șirului construit cu metoda Gauss-Seidel doar în cazul în care matricea  $A$  este pozitiv definită:

$$x^{(k)} \rightarrow x^*, \quad k \rightarrow \infty \Leftrightarrow \rho(M) < 1 \Leftrightarrow A \text{ pozitiv definită}$$

## Metodele relaxării

Fie  $A \in \mathbb{R}^{n \times n}$  o matrice reală pătratică de dimensiune  $n$ , simetrică,  $A=A^T$  și pozitiv definită,  $A > 0$  și  $b \in \mathbb{R}^n$  un vector real. Considerăm sistemul de ecuații liniare:

$$Ax = b$$

Deoarece matricea  $A$  este pozitiv definită sistemul de mai sus are soluție unică,  $x^* = A^{-1}b$ . Vom considera funcția  $f : \mathbb{R}^n \rightarrow \mathbb{R}_+$ :

$$f(y) = \left( A(x^* - y), x^* - y \right)_{\mathbb{R}^n}, \quad y \in \mathbb{R}^n$$

Din faptul că matricea  $A$  este pozitiv definită avem:

$$f(y) \geq 0, \forall y \in \mathbb{R}^n \quad \text{și} \quad f(y) > 0 = f(x^*), \forall y \neq x^*$$

Prin urmare  $x^*$  este și unica soluție a problemei de minimizare:

$$\min \{ f(y); y \in \mathbb{R}^n \} = 0 = f(x^*)$$

Vom căuta soluția sistemului  $Ax=b$ ,  $x^* = A^{-1}b$  ca fiind soluția problemei de minimizare de mai sus folosind o metodă de tip relaxare de forma:

$$\mathbf{y}^{(0)} \in \mathbb{R}^n - \text{dat}, \quad \mathbf{y}^{(k+1)} = \mathbf{y}^{(k)} + c_k \mathbf{e}_l, \quad l = l_k, \quad k = 0, 1, \dots$$

$$y_j^{(k+1)} = y_j^{(k)}, \quad \forall j \neq l, \quad y_l^{(k+1)} = y_l^{(k)} + c_k$$

Constanta  $c_k$  se determină astfel încât  $f(\mathbf{y}^{(k+1)}) < f(\mathbf{y}^{(k)})$  în speranța că șirul  $\mathbf{y}^{(k)}$  astfel construit converge la  $\mathbf{x}^*$ . Notăm cu

$$\mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{y}^{(k)} \quad \text{vectorul reziduu.}$$

Avem:

$$\mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{y}^{(k)} = A\mathbf{x}^* - A\mathbf{y}^{(k)} = A(\mathbf{x}^* - \mathbf{y}^{(k)})$$

$$f(\mathbf{y}^{(k+1)}) = f(\mathbf{y}^{(k)}) - 2c_k r_l^{(k)} + c_k^2 a_{ll}$$

Pentru ca  $f(y^{(k+1)}) < f(y^{(k)})$  este necesar și suficient să alegem  $c_k$  astfel ca:

$$c_k^2 a_{ll} - 2 c_k r_l^{(k)} < 0 \Leftrightarrow (a_{ll} > 0) c_k \in \left( 0, 2 \frac{r_l^{(k)}}{a_{ll}} \right) \text{ sau } \left( 2 \frac{r_l^{(k)}}{a_{ll}}, 0 \right)$$

$$c_k = \omega_k \frac{r_l^{(k)}}{a_{ll}}, \text{ cu } \omega_k \in (0, 2)$$

Metoda de relaxare obținută este următoarea:

$$y^{(0)} \in \mathbb{R}^n - \text{dat}, \quad y^{(k+1)} = y^{(k)} + \omega_k \frac{r_l^{(k)}}{a_{ll}} e_l, \quad k = 0, 1, \dots, \quad \omega_k \in (0, 2)$$

Pentru a aproxima  $\mathbf{x}^*$  se deduce o clasă de metode numite *metodele relaxării succesive*. Aceste metode se obțin aplicând metodele de relaxare de mai sus. Vom considera:

$$\omega_k = \omega, \forall k$$

Vom construi un șir  $\{\mathbf{x}^{(k)}\} \subseteq \mathbb{R}^n$  astfel:

$\mathbf{x}^{(0)} = \mathbf{y}^{(0)}$  un vector din  $\mathbb{R}^n$  dat

$$l = 1 \quad \mathbf{y}^{(1)} = \mathbf{y}^{(0)} + \omega \frac{\mathbf{r}_1^{(0)}}{a_{11}} \mathbf{e}_1$$

$$l = 2 \quad \mathbf{y}^{(2)} = \mathbf{y}^{(1)} + \omega \frac{\mathbf{r}_2^{(1)}}{a_{22}} \mathbf{e}_2$$

$\vdots$

$$l = n \quad \mathbf{y}^{(n)} = \mathbf{y}^{(n-1)} + \omega \frac{\mathbf{r}_n^{(n-1)}}{a_{nn}} \mathbf{e}_n$$

$$\mathbf{x}^{(1)} = \mathbf{y}^{(n)}$$

Trecerea de la iterația  $k$  la iterația următoare se face astfel:

$$\mathbf{x}^{(k)} = \mathbf{y}^{(kn)}$$

$$l = 1 \quad \mathbf{y}^{(kn+1)} = \mathbf{y}^{(kn)} + \omega \frac{\mathbf{r}_1^{(kn)}}{a_{11}} \mathbf{e}_1$$

$$l = 2 \quad \mathbf{y}^{(kn+2)} = \mathbf{y}^{(kn+1)} + \omega \frac{\mathbf{r}_2^{(kn+1)}}{a_{22}} \mathbf{e}_2$$

$\vdots$

$$l = n \quad \mathbf{y}^{(kn+n)} = \mathbf{y}^{(kn+n-1)} + \omega \frac{\mathbf{r}_n^{(kn+n-1)}}{a_{nn}} \mathbf{e}_n$$

$$\mathbf{x}^{(k+1)} = \mathbf{y}^{((k+1)n)}, \quad k = 0, 1, 2, \dots$$



Acum putem scrie dependența vectorului  $\mathbf{x}^{(k+1)}$  de  $\mathbf{x}^{(k)}$ :

$\mathbf{x}^{(0)} \in \mathbb{R}^n$ ,  $\omega \in (0, 2)$  date,

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n,$$

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n,$$

$$k = 0, 1, 2, \dots$$

Metodele de mai sus poartă numele de *metodele relaxării succesive*. Pentru  $\omega = 1$  obținem metoda Gauss-Seidel.

- $0 < \omega < 1$  metodele se numesc de *sub-relaxare* și pot fi folosite în cazul când metoda Gauss-Seidel diverge.
- $1 < \omega < 2$  metodele se numesc de *supra-relaxare* și pot fi folosite pentru accelerarea convergenței în cazul când metoda Gauss-Seidel converge.

Rearanjând formulele de mai sus avem:

$$\begin{aligned} \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} + \frac{a_{ii}}{\omega} x_i^{(k+1)} &= \left( B x^{(k+1)} \right)_i = \frac{(1-\omega)}{\omega} a_{ii} x_i^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i = \\ &= \left( C x^{(k)} \right)_i + (b)_i \end{aligned}$$

Matricea  $A$  fiind simetrică, poate fi scrisă sub forma:

$$A = L + D + L^T \quad \text{cu} \quad L = \begin{pmatrix} \mathbf{0} & \mathbf{0} & \cdots & 0 & \mathbf{0} \\ a_{21} & \mathbf{0} & \cdots & 0 & \mathbf{0} \\ \vdots & & & & \\ a_{n1} & a_{n2} & \cdots & a_{nn-1} & \mathbf{0} \end{pmatrix},$$

$$D = \text{diag}[a_{11}, a_{22}, \dots, a_{nn}]$$

Cu aceste notații, matricile  $\mathbf{B}$  și  $\mathbf{C}$  de mai sus pot fi scrise astfel:

$$\mathbf{B} = \mathbf{L} + \frac{1}{\omega} \mathbf{D} \quad , \quad \mathbf{C} = \frac{1-\omega}{\omega} \mathbf{D} - \mathbf{L}^T$$

Vom verifica dacă metodele relaxării succesive se înscriu în clasa generală de metode iterative, adică vom verifica dacă  $\mathbf{A} = \mathbf{B} - \mathbf{C}$  :

$$\mathbf{B} - \mathbf{C} = \mathbf{L} + \frac{1}{\omega} \mathbf{D} - \frac{1-\omega}{\omega} \mathbf{D} + \mathbf{L}^T = \mathbf{L} + \mathbf{D} + \mathbf{L}^T = \mathbf{A}$$

Convergența șirului  $\mathbf{x}^{(k)}$  la soluția  $\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}$  ?

## Teoremă

Fie o matrice  $A \in \mathbb{R}^{n \times n}$ , simetrică,  $A=A^T$  cu  $\det A \neq 0$ ,  $a_{ii} > 0$ ,  $\forall i = 1, \dots, n$ ,  $b \in \mathbb{R}^n$  un vector real și  $\omega \in (0, 2)$ . Atunci șirul  $x^{(k)}$  construit cu o metoda de relaxare succesivă converge la soluția  $x^*$  a sistemului liniar  $Ax=b$  oricare ar fi iterația inițială  $x^{(0)}$  dacă și numai dacă matricea  $A$  este pozitiv definită.

$$x^{(k)} \rightarrow x^*, k \rightarrow \infty, \forall x^{(0)} \Leftrightarrow (Ax, x) > 0, \forall x \in \mathbb{R}^n, x \neq 0$$

Demonstrație: Vom verifica dacă raza spectrală a matricei iterației este subunitară folosind **Lema**. Avem:

$$\mathbf{M} = \mathbf{B}^{-1}\mathbf{C} = \mathbf{B}^{-1}(\mathbf{B} - \mathbf{A}) = \mathbf{I}_n - \mathbf{B}^{-1}\mathbf{A}$$

$$\mathbf{B} = \mathbf{L} + \frac{1}{\omega}\mathbf{D} \quad , \quad \det \mathbf{B} = \frac{1}{\omega^n} a_{11}a_{22} \cdots a_{nn} \neq 0 \quad (a_{ii} > 0, \forall i)$$

Matricea  $\mathbf{A}$  este simetrică iar matricea  $\mathbf{B}$  este nesingulară. Pentru a fi îndeplinite ipotezele Lemei trebuie să verificăm că matricea  $\mathbf{P}$  este pozitiv definită:

$$\mathbf{P} = \mathbf{B} + \mathbf{B}^T - \mathbf{A} = \mathbf{L} + \frac{1}{\omega}\mathbf{D} + \mathbf{L}^T + \frac{1}{\omega}\mathbf{D} - \mathbf{L} - \mathbf{D} - \mathbf{L}^T = \frac{2-\omega}{\omega}\mathbf{D}$$

$$\begin{aligned}
(Px, x) &= \frac{(2-\omega)}{\omega} \sum_{i=1}^n a_{ii} x_i^2 > 0, \quad x \neq 0 \quad (a_{ii} > 0, \forall i) \Leftrightarrow \\
&\Leftrightarrow \frac{(2-\omega)}{\omega} > 0 \quad \Leftrightarrow \omega \in (0, 2)
\end{aligned}$$

Toate ipotezele lemei sunt îndeplinite, prin urmare avem convergența dorită.

## Valori și vectori proprii (eigenvalues, eigenvectors)

### Definiție

Fie  $A \in \mathbb{R}^{n \times n}$ . Numărul complex  $\lambda \in \mathbb{C}$  se numește *valoare proprie* a matricei  $A$  dacă există un vector  $u \in \mathbb{C}^n$ ,  $u \neq 0$  astfel ca:

$$Au = \lambda u$$

Vectorul  $u$  se numește *vector propriu* asociat valorii proprii  $\lambda$ .

Pentru existența vectorului  $u \neq 0$  este necesar și suficient ca matricea  $(\lambda I_n - A)$  să fie singulară, adică  $\det(\lambda I_n - A) = 0$ .



Polinomul de grad  $n$ :

$$p_A(\lambda) = \det(\lambda I_n - A)$$

se numește *polinom caracteristic* al matricei  $A$ .

### Propoziția 1

Fie rădăcinile polinomului caracteristic  $\lambda_1, \lambda_2, \dots, \lambda_n$  distincte,  $\lambda_i \neq \lambda_j$  pentru  $1 \leq i < j \leq n$  și  $u_1, u_2, \dots, u_n$  vectorii proprii corespunzători. Atunci  $u_1, u_2, \dots, u_n$  sunt liniar independenți. (demonstrația se face prin inducție)

## Propoziția 2

Fie valorile proprii  $\lambda_i$  ale matricei  $A \in \mathbb{R}^{n \times n}$  distincte. Atunci există o matrice nesingulară  $T$  astfel ca:

$$T^{-1}AT = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_n].$$

Demonstrație. Fie  $u_1, u_2, \dots, u_n$  vectorii proprii ai matricei  $A$ . Considerăm matricea  $T$  ale cărei coloane sunt vectorii proprii  $u_i$ ,  $T = [u_1 \ u_2 \ \dots \ u_n]$ . Deoarece vectorii proprii sunt liniar independenți conform propoziției 1 rezultă că matricea  $T$  este nesingulară. Vom avea:

$$AT = [Au_1 \ Au_2 \ \dots \ Au_n] = [\lambda_1 u_1 \ \lambda_2 u_2 \ \dots \ \lambda_n u_n] = T \cdot \text{diag}[\lambda_1 \ \lambda_2 \ \dots \ \lambda_n]$$

Înmulțind la stânga cu  $T^{-1}$  obținem concluzia propoziției 2.

## Definiție

**Matricile**  $A$  și  $B$  sunt *asemenea* (notație  $A \sim B$ ) dacă și numai dacă există o matrice nesingulară  $T$  ( $\det T \neq 0$ ) astfel ca:

$$A = T B T^{-1}$$

## Propoziția 3

$$A \sim B \Rightarrow p_A(\lambda) = p_B(\lambda).$$

Demonstrație.

$$\begin{aligned} p_A(\lambda) &= \det(\lambda I_n - A) = \det(\lambda I_n - T B T^{-1}) = \det(\lambda T T^{-1} - T B T^{-1}) \\ &= \det(T(\lambda I_n - B)T^{-1}) = \det(T) \det(\lambda I_n - B) \det(T^{-1}) = p_B(\lambda) \end{aligned}$$

Propoziția 3 ne spune că matricele asemenea au același polinom caracteristic și aceleași valori proprii.

## Teorema lui Gershgorin

Fie  $A \in \mathbb{R}^{n \times n}$  și  $\lambda \in \mathbb{C}$  o valoare proprie oarecare a matricei  $A$ .  
Atunci:

$$\exists i_0 \in \{1, 2, \dots, n\} \text{ astfel încât } |\lambda - a_{i_0 i_0}| \leq r_{i_0}, \quad r_{i_0} = \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{i_0 j}|.$$

(Valoarea proprie  $\lambda$  se află în cercul din planul complex de centru  $a_{i_0 i_0}$  și rază  $r_{i_0}$ .)

Demonstrație. Fie  $\lambda \in \mathbb{C}$  o valoare proprie a matricei  $A$  și  $u \neq 0$  un vector propriu asociat valorii proprii  $\lambda$ ,  $Au = \lambda u$ .

Avem:

$$\lambda u_i = a_{ii}u_i + \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}u_j \Leftrightarrow (\lambda - a_{ii})u_i = \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}u_j, i = 1, \dots, n.$$

Fie  $i_0$  astfel ca  $|u_{i_0}| = \|u\|_\infty = \max\{|u_k|; k = 1, \dots, n\} > 0$  ( $u \neq 0$ ).

Vom avea:

$$|\lambda - a_{i_0 i_0}| = \left| \sum_{\substack{j=1 \\ j \neq i_0}}^n a_{i_0 j} \frac{u_j}{u_{i_0}} \right| \leq \sum_{\substack{j=1 \\ j \leq i_0}}^n |a_{i_0 j}| \frac{|u_j|}{|u_{i_0}|} \leq r_{i_0}, \text{ ținând seama că } \frac{|u_j|}{|u_{i_0}|} \leq 1.$$

**Observație.** Presupunem că matricea  $A$  are  $n$  vectori proprii liniar independenți  $u^1, u^2, \dots, u^n$  asociați valorilor proprii  $\lambda_1, \lambda_2, \dots, \lambda_n$ . Fie  $U = [u^1 \ u^2 \ \dots \ u^n]$ . Datorită independenței vectorilor  $u^k$  rezultă că matricea  $U$  este nesingulară și avem:

$$\Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_n] \quad U^{-1}AU = \Lambda.$$

Considerăm matricea perturbată:

$$A(\varepsilon) = A + \varepsilon B.$$

$$U^{-1}A(\varepsilon)U = \Lambda + \varepsilon U^{-1}BU = \Lambda + \varepsilon C.$$

$$A(\varepsilon) \sim U^{-1}A(\varepsilon)U \Rightarrow \text{au aceleași valori proprii } \lambda_i(\varepsilon)$$

$$|\lambda(\varepsilon) - \lambda_i - \varepsilon c_{ii}| \leq \varepsilon \sum_{\substack{j=1 \\ j \neq i}}^n |c_{ij}| \Rightarrow |\lambda(\varepsilon) - \lambda_i| = \mathcal{O}(\varepsilon).$$

## Metoda puterii pentru matrice simetrice

### Propoziție

Fie  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$ . Atunci toate valorile proprii ale matricei  $A$  sunt numere reale.

Demonstrație. Fie  $\lambda \in \mathbb{C}$  și  $u \in \mathbb{C}^n$ ,  $u \neq 0$ ,  $Au = \lambda u$ .

Considerăm produsul scalar:

$$(Au, u)_{\mathbb{C}^n} = \lambda (u, u)_{\mathbb{C}^n} = \lambda \|u\|_2^2.$$

$$(Au, u)_{\mathbb{C}^n} = (u, A^T u)_{\mathbb{C}^n} = (u, Au)_{\mathbb{C}^n} = \overline{(Au, u)_{\mathbb{C}^n}} \Rightarrow (Au, u)_{\mathbb{C}^n} \in \mathbb{R}$$

$$\lambda = \frac{(Au, u)_{\mathbb{C}^n}}{\|u\|_2^2} \in \mathbb{R}.$$

### Propoziție

Fie  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$ . Atunci există o bază ortonormată de vectori proprii ai matricei  $A$ ,  $\{u^1, u^2, \dots, u^n\}$  :

$$(u^i, u^j)_{\mathbb{R}^n} = \delta_{ij} = \begin{cases} 1 & \text{dacă } i = j \\ 0 & \text{dacă } i \neq j \end{cases}$$

Echivalent, putem scrie ca există vectori proprii  $\{u^1, u^2, \dots, u^n\}$  asociați valorilor proprii reale  $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$  astfel ca:

$$AU = U\Lambda \Leftrightarrow U^T AU = \Lambda$$

cu  $\Lambda = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_n]$  și  $U = [u^1 \ u^2 \ \dots \ u^n]$  matrice ortogonală.



## Definiție

Se numește *coeficient Rayleigh* al vectorului  $\mathbf{u} \in \mathbb{R}^n$  pentru matricea  $A$  următoarea mărime scalară:

$$r(\mathbf{u}) = \frac{\mathbf{u}^T A \mathbf{u}}{\mathbf{u}^T \mathbf{u}} = \frac{(A\mathbf{u}, \mathbf{u})_{\mathbb{R}^n}}{(\mathbf{u}, \mathbf{u})_{\mathbb{R}^n}} = \frac{(A\mathbf{u}, \mathbf{u})_{\mathbb{R}^n}}{\|\mathbf{u}\|_2^2}$$

Se verifică ușor că dacă  $\mathbf{u} \in \mathbb{R}^n$  este vector propriu al matricei  $A$  asociat valorii proprii  $\lambda$  atunci  $r(\mathbf{u}) = \lambda$ .

Fie  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$ . Matricea are valori proprii reale  $\lambda_1, \lambda_2, \dots, \lambda_n$ . Presupunem în plus că:

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n| \geq 0$$

Metoda puterii este un algoritm care aproximează valoarea proprie de modul maxim  $\lambda_1$  și un vector propriu asociat.

Se pornește de la un vector nenul de normă euclidiană 1,  $\mathbf{u}^{(0)} \in \mathbb{R}^n$ ,  $\|\mathbf{u}^{(0)}\|_2 = 1$  și se construiește următorul șir de vectori de normă euclidiană 1:

$$\mathbf{u}^{(0)}, \mathbf{u}^{(1)} = \frac{1}{\|A\mathbf{u}^{(0)}\|_2} A\mathbf{u}^{(0)}, \mathbf{u}^{(2)} = \frac{1}{\|A\mathbf{u}^{(1)}\|_2} A\mathbf{u}^{(1)}, \dots,$$

$$\mathbf{u}^{(k)} = \frac{1}{\|A\mathbf{u}^{(k-1)}\|_2} A\mathbf{u}^{(k-1)}, \dots$$

În anumite condiții acest șir converge la un vector propriu asociat valorii proprii  $\lambda_1$ , iar coeficienții Rayleigh corespunzători converg către  $\lambda_1$ .

## Teoremă

Fie  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$  o matrice simetrică pentru care valorile proprii îndeplinesc condiția:

$$|\lambda_1| > |\lambda_2| \geq \dots |\lambda_n| \geq 0.$$

Dacă  $u^{(0)} \in \mathbb{R}^n$ ,  $\|u^{(0)}\|_2 = 1$ ,  $(u^{(0)}, u^1)_{\mathbb{R}^n} \neq 0$  ( $u^1$  vector propriu asociat lui  $\lambda_1$ ) atunci:

$$u^{(k)} = \frac{1}{\|A^k u^{(0)}\|_2} A^k u^{(0)} \rightarrow u^1 \text{ (vector propriu asociat lui } \lambda_1 \text{)}$$

$$r(u^{(k)}) \rightarrow \lambda_1$$

Demonstrație. Fie  $\{u^1, u^2, \dots, u^n\}$  vectori proprii asociați valorilor proprii  $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$  care formează o bază ortonormată în  $\mathbb{R}^n$ . Avem:

$$u^{(0)} = a_1 u^1 + a_2 u^2 + \dots + a_n u^n, \quad a_i \in \mathbb{R}$$

Deoarece  $(u^{(0)}, u^1)_{\mathbb{R}^n} \neq 0$  rezultă că  $a_1 \neq 0$ . Din construcția șirului  $u^{(k)}$  deducem că există o constantă  $c_k$  astfel ca:

$$\begin{aligned}
\mathbf{u}^{(k)} &= \mathbf{c}_k \mathbf{A}^k \mathbf{u}^{(0)} = \\
&= \mathbf{c}_k \mathbf{A}^k (a_1 \mathbf{u}^1 + a_2 \mathbf{u}^2 + \dots + a_n \mathbf{u}^n) = \\
&= \mathbf{c}_k (a_1 \lambda_1^k \mathbf{u}^1 + a_2 \lambda_2^k \mathbf{u}^2 + \dots + a_n \lambda_n^k \mathbf{u}^n) = \\
&= \mathbf{c}_k \lambda_1^k \left[ a_1 \mathbf{u}^1 + a_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{u}^2 + \dots + a_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{u}^n \right]
\end{aligned}$$

Din această ultimă relație, din faptul că  $\lambda_1$  este valoare proprie dominantă și  $a_1 \neq 0$  deducem că pentru  $k$  suficient de mare vectorul  $\mathbf{u}^{(k)}$  se aliniază după vectorul propriu  $\mathbf{u}^1$ :

$$\mathbf{u}^{(k)} \approx \mathbf{c}_k \lambda_1^k a_1 \mathbf{u}^1$$

## Metoda puterii

$$\mathbf{u}^{(0)} \in \mathbb{R}^n, \|\mathbf{u}^{(0)}\|_2 = 1;$$

$$k = 0;$$

*do*

$$\circ k++;$$

$$\circ \mathbf{w} = A\mathbf{u}^{(k-1)};$$

$$\circ \mathbf{u}^{(k)} = \frac{1}{\|\mathbf{w}\|_2} \mathbf{w};$$

$$\circ \lambda_k = r(\mathbf{u}^{(k)}) = \left( A\mathbf{u}^{(k)}, \mathbf{u}^{(k)} \right)_{\mathbb{R}^n};$$

$$\textit{while} (\|A\mathbf{u}^{(k)} - \lambda_k \mathbf{u}^{(k)}\| > \varepsilon \text{ și } k \leq k_{\max});$$

## Metoda iterației inverse

Considerăm o matrice simetrică  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$  și  $\mu \in \mathbb{R}$  un număr real care nu este valoare proprie a matricei  $A$ . Vom folosi metoda puterii pentru a aproxima valoarea proprie a matricei  $A$  care este cea mai apropiată de  $\mu$  și un vector propriu asociat.

$$\mu \neq \text{valoare proprie} \rightarrow \det(A - \mu I_n) \neq 0 \rightarrow \exists (A - \mu I_n)^{-1}$$

Fie  $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$  valorile proprii reale ale matricei  $A$ .

Valorile proprii ale matricei  $(A - \mu I_n)^{-1}$  sunt:

$$\left\{ \frac{1}{(\lambda_1 - \mu)}, \frac{1}{(\lambda_2 - \mu)}, \dots, \frac{1}{(\lambda_n - \mu)} \right\}$$

Matricele  $A$  și  $(A - \mu I_n)^{-1}$  au aceiași vectori proprii. Să presupunem că  $\lambda_I$  este valoarea proprie cea mai apropiată de  $\mu$  (și singura). Atunci:

$$\frac{1}{|\lambda_I - \mu|} > \frac{1}{|\lambda_j - \mu|} \quad \forall j \neq I$$



Această relație sugerează ideea aplicării metodei puterii matricei  $(A - \mu I_n)^{-1}$  pentru a aproxima valoarea proprie  $(\lambda_I - \mu)^{-1}$  și a unui vector propriu asociat. Algoritmul duce la aproximarea valorii proprii cea mai apropiată de  $\mu$ ,  $\lambda_I$  și a unui vector propriu asociat acestei autovalori,  $u^I$ .

## Metoda iterației inverse

$$\mathbf{u}^{(0)} \in \mathbb{R}^n, \|\mathbf{u}^{(0)}\|_2 = 1;$$

$$k = 0;$$

*do*

$$\circ k++;$$

$$\circ \text{Se rezolvă sistemul } (A - \mu I_n) \mathbf{w} = \mathbf{u}^{(k-1)};$$

$$\circ \mathbf{u}^{(k)} = \frac{1}{\|\mathbf{w}\|_2} \mathbf{w};$$

$$\circ \lambda_k = r(\mathbf{u}^{(k)}) = \left( A\mathbf{u}^{(k)}, \mathbf{u}^{(k)} \right)_{\mathbb{R}^n};$$

$$\text{while } (\|A\mathbf{u}^{(k)} - \lambda_k \mathbf{u}^{(k)}\| > \varepsilon \text{ și } k \leq k_{\max});$$