

# **Calcul Numeric**

**Cursul 8**

**2022**

*Anca Ignat*

## Forma superioară Hessenberg

Spunem că o matrice  $H \in \mathbb{R}^{n \times n}$  este în *formă superioară Hessenberg* dacă:

$$h_{ij} = 0, i = 1, \dots, n, j = 1, \dots, i - 2$$

O matrice în formă Hessenberg arată astfel:

$$H = \begin{pmatrix} h_{11} & h_{12} & h_{13} & \cdots & h_{1n-1} & h_{1n} \\ h_{21} & h_{22} & h_{23} & \cdots & h_{2n-1} & h_{2n} \\ \mathbf{0} & h_{32} & h_{33} & \cdots & h_{3n-1} & h_{3n} \\ \mathbf{0} & \mathbf{0} & h_{43} & \cdots & h_{4n-1} & h_{4n} \\ \vdots & & & & & \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & h_{nn-1} & h_{nn} \end{pmatrix}$$

Ne interesează un algoritm care să transforme o matrice pătratică  $A$  oarecare într-o matrice Hessenberg superioară  $H$  care să aibă aceleași valori proprii:

$A \rightarrow H$  a.î.  $H \sim A$ ,  $H = \tilde{P}A \tilde{P}^{-1}$ ,  $\tilde{P}$  matrice nesingulară  
Algoritmul este o adaptare a algoritmului lui Housholder și se desfășoară în  $(n-2)$  pași, folosind matricile de reflexie pentru a transforma matricea.

### **Pas 1**

se efectuează operațiile  $A = P_1 A P_1$  (matricea  $P_1$  se alege astfel încât coloana 1 să fie transformată în formă superior Hessenberg)

## Pas 2

$$A = P_2 A P_2 = P_2 (P_1 A^{init}) P_2$$

( $P_2$  transformă coloana 2 în formă superior Hessenberg fără să schimbe coloana 1)

## Pas $r$

$$A = P_r A P_r = P_r (P_{r-1} \cdots P_1 A^{init} P_1 \cdots P_{r-1}) P_r$$

(se transformă coloana  $r$  în formă superior Hessenberg fără să schimbe primele  $(r-1)$  coloane)

### Pasul $r$ ( $r=1,2,\dots,n-2$ )

La intrarea în pasul  $r$  matricea  $A$  are primele  $(r-1)$  coloane în formă superior Hessenberg. La ieșirea din pasul  $r$  matricea  $A$  va avea primele  $r$  coloane în formă superior Hessenberg:

$$A_{ies} = P_r A_{intr} P_r , \quad A_{ies} \sim A_{intr}$$

$$P_r = I_n - 2v^r (v^r)^T , \quad v^r \in R^n , \quad \|v^r\|_2 = 1$$

Vectorul  $v^r$  se alege astfel ca matricea  $A_{ies}$  să aibă coloana  $r$  în formă superior Hessenberg și să nu schimbe primele  $(r-1)$  coloane ale matricii  $A_{intr}$ .

## Calculul matricii $P_r$

$$P = I_n - \frac{1}{\beta} uu^T$$

$$\beta = \sigma - k \cdot a_{r+1r}$$

$$k^2 = \sigma = a_{r+1r}^2 + \cdots + a_{ir}^2 + \cdots + a_{nr}^2 = \sum_{i=r+1}^n a_{ir}^2 \Rightarrow k = \pm \sqrt{\sigma}$$

$$\text{semn } k = -\text{semn } a_{r+1r}$$

$$u := \begin{pmatrix} \mathbf{0} \\ \vdots \\ \mathbf{0} \\ a_{r+1r} - k \\ \vdots \\ a_{ir} \\ \vdots \\ a_{nr} \end{pmatrix}$$

$$\beta = \mathbf{0} \rightarrow r = r + 1 \ (P = I_n)$$



Algoritmul de trecere de la matricea  $A$  la matricea  $P_r A$  este următorul:

$$(P_r A)e_j = \begin{cases} Ae_j & \text{pentru } j = 1, \dots, r-1 \\ (a_{1r}, a_{2r}, \dots, a_{rr}, k, 0, \dots, 0)^T & \text{pentru } j = r \\ Ae_j - \frac{\gamma_j}{\beta} u & \text{pentru } j = r+1, \dots, n \end{cases}$$

$$\gamma_j = (Ae_j, u)_{\mathbb{R}^n} = \sum_{i=r+1}^n u_i a_{ij}$$

$$u_i = 0, \quad i = 1, \dots, r, \quad u_{r+1} = a_{r+1r} - k, \quad u_i = a_{ir}, \quad i = r+2, \dots, n$$

Vom descrie în continuare cum se efectuează operația  $A := AP_r$  fără a face înmulțire matricială (matricea  $A$  este cea obținută mai sus având primele  $r$  coloane în formă superior Hessenberg).

Vom arata că această operație nu schimbă forma superior Hessenberg obținută. Vom pune în evidență transformările liniilor matricii  $A$ . Pentru  $i=1, \dots, n$  avem:

$$\begin{aligned} e_i^T (AP) &= \text{noua linie } i \text{ a matricii } AP = (e_i^T A) \left( I_n - \frac{1}{\beta} uu^T \right) = \\ &= e_i^T A - \frac{1}{\beta} (e_i^T A) u u^T = e_i^T A - \frac{\gamma_i}{\beta} u^T \end{aligned}$$

unde

$$\gamma_i = (e_i^T A)u = a_{ir+1}u_{r+1} + \cdots + a_{in}u_n$$

Elementele liniei  $i$  se schimbă astfel:

$$a_{ij} = a_{ij} - \frac{\gamma_i}{\beta} u_j, \quad j = r+1, \dots, n, \quad i = 1, \dots, n$$

Operația  $A := AP_r$  nu modifică primele  $r$  coloane ale matricii  $A$ , ele rămânând în formă superior Hessenberg.

## *Algoritmul de obținere a formei superior Hessenberg*

for  $r = 1, \dots, n - 2$

// construcția matricii  $P_r$  – constanta  $\beta$  și vectorul  $u$

- $\sigma = \sum_{i=r+1}^n a_{ir}^2;$
- if (  $\sigma \leq \varepsilon$  ) break ; //  $r = r + 1 \leftrightarrow P_r = I_n$
- $k = \sqrt{\sigma};$
- if (  $a_{r+1r} > 0$  )  $k = -k;$
- $\beta = \sigma - k a_{r+1r};$
- $u_{r+1} = a_{r+1r} - k; u_i = a_{ir}, i = r + 2, \dots, n;$

//  $A = P_r * A$

// transformarea coloanelor  $j = r + 1, \dots, n$

- for  $j = r + 1, \dots, n$

$$\left\{ \begin{array}{l} \gamma = (\gamma_j / \beta) = (Ae_j, u) / \beta = (\sum_{i=r+1}^n u_i a_{ij}) / \beta; \\ \text{for } i = r + 1, \dots, n \\ a_{ij} = a_{ij} - \gamma * u_i; \end{array} \right.$$

// transformarea coloanei  $r$  a matricii  $A$

- $a_{r+1r} = k$  ;  $a_{ir} = 0$ ,  $i = r + 2, \dots, n$  ;

$$// \mathbf{A} = \mathbf{A} * \mathbf{P}_r$$

// transformarea liniilor  $i = 1, \dots, n$

• for  $i = 1, \dots, n$

$$\left\{ \begin{array}{l} \gamma = (\gamma_i / \beta) = ((e_i^T \mathbf{A})\mathbf{u}) / \beta = (\sum_{j=r+1}^n u_j a_{ij}) / \beta; \\ \text{for } j = r + 1, \dots, n \\ \quad a_{ij} = a_{ij} - \gamma * u_j; \end{array} \right.$$

## Algoritmul *QR* de aproximare a valorilor proprii ale unei matrice oarecare

Prezentăm în continuare cel mai folosit algoritm de aproximare a valorilor proprii pentru matrice pătratice oarecare.

Spunem că o matrice  $S \in \mathbb{R}^{n \times n}$  este în *formă Schur reală* dacă matricea  $S$  este în formă superior Hessenberg și în plus este bloc-diagonală:

$$S = \begin{pmatrix} S_{11} & S_{12} & \cdots & S_{1p} \\ \mathbf{0} & S_{22} & \cdots & S_{2p} \\ \vdots & & & \\ \mathbf{0} & \mathbf{0} & \cdots & S_{pp} \end{pmatrix}$$

blocurile  $S_{ii}$  sunt astfel ca:

- $S_{ii} \in \mathbb{R}$  - este valoare proprie reală
- $S_{ii} \in \mathbb{R}^{2 \times 2}$  - este bloc corespunzător valorilor proprii complexe

Valorile proprii corespunzătoare blocului

$S_{ii} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \in \mathbb{R}^{2 \times 2}$  sunt rădăcinile ecuației:



$$\begin{vmatrix} \lambda - a & -b \\ -c & \lambda - d \end{vmatrix} = (\lambda - a)(\lambda - d) - bc = \lambda^2 - (a + d)\lambda + ad - bc = 0$$

Se presupune că această ecuație de gradul 2 are rădăcini complexe.

**Algoritmul QR** de aproximare a valorilor proprii construiește un șir de matrici  $A^{(k)} \in \mathbb{R}^{n \times n}$ , matrici asemenea cu matricea  $A$ ,  $A^{(k)} \sim A, \forall k$ , șir care converge la o matrice în formă Schur reală,  $A^{(k)} \rightarrow S, k \rightarrow \infty$ . Matricea limită  $S$  este asemenea cu matricea  $A$ , valorile proprii ale matricii  $S$  fiind ușor de calculat. Șirul  $A^{(k)}$  se construiește astfel:

$$A^{(0)} := A, \quad A^{(0)} = Q_0 R_0 \text{ (descomp. } QR \text{ calc. pentru matricea } A^{(0)})$$

$$A^{(1)} := R_0 Q_0, \quad A^{(1)} = Q_1 R_1 \text{ (descomp. } QR \text{ calc. pentru matricea } A^{(1)})$$

$$A^{(2)} := R_1 Q_1$$

$\vdots$

$$A^{(k)} = Q_k R_k \text{ (descomp. } QR \text{ calc. pentru matricea } A^{(k)}) ,$$

$$A^{(k+1)} := R_k Q_k, \quad k = 0, 1, 2, \dots$$

Matricile  $Q_k$  sunt matrici ortogonale ( $Q_k^{-1} = Q_k^T$ ) iar matricile  $R_k$  sunt superior triunghiulare.

Matricile  $A^{(k)}$  și  $A^{(k+1)}$  sunt asemenea:

$$\begin{aligned} Q_k^T * | A^{(k)} = Q_k R_k &\Rightarrow R_k = Q_k^T A^{(k)} \\ A^{(k+1)} = R_k Q_k = Q_k^T A^{(k)} Q_k &\Rightarrow A^{(k+1)} \sim A^{(k)}, \forall k \end{aligned}$$

Matricile șirului construit sunt toate asemenea prin urmare au aceleași valori proprii anume cele ale matricii inițiale  $A = A^{(0)}$ :

$$A = A^{(0)} \sim A^{(1)} \sim \dots \sim A^{(k)} \sim \dots \sim S$$

Dacă matricea  $A^{(k)}$  este în formă superioară Hessenberg, atunci descompunerea  $QR$  realizată cu algoritmul lui Givens se simplifică. Reamintim algoritmul lui Givens:

$$R_{n-1n}(\theta_{n-1n}) \cdots R_{pn}(\theta_{pn}) \cdots R_{pp+1}(\theta_{pp+1}) \cdots R_{1n}(\theta_{1n}) \cdots R_{12}(\theta_{12}) A = R$$

Dacă matricea  $A$  este în formă Hessenberg în algoritmul lui Givens, din cele  $\frac{n(n-1)}{2}$  înmulțiri cu matrici de rotație rămân doar  $(n-1)$ :

$$R_{n-1n}(\theta_{n-1n}) \cdots R_{pp+1}(\theta_{pp+1}) \cdots R_{23}(\theta_{23}) R_{12}(\theta_{12}) A = R.$$

Problema care se pune este dacă pornind cu o matrice în formă Hessenberg, toate matricile șirului rămân în formă Hessenberg:

$A^{(k)}$  (în formă Hessenberg) =  $H = QR$  (cu Givens)  $\Rightarrow ?$

$A^{(k+1)} = \bar{H} = RQ = Q^T A^{(k)} Q = Q^T H Q$  – este tot în formă Hessenberg ?

Avem:

$$\bar{H} = Q^T H Q = R R_{12}^T(\theta_{12}) \cdots R_{rr+1}^T(\theta_{rr+1}) \cdots R_{n-1n}^T(\theta_{n-1n})$$

Notăm cu:

$$\bar{R} = R R_{12}^T(\theta_{12})$$

pentru care avem:

$$\begin{cases} \bar{r}_{i1} = cr_{i1} + sr_{i2} , \forall i \\ \bar{r}_{i2} = -sr_{i1} + cr_{i2} , \forall i \end{cases} + \begin{cases} r_{i1} = 0, i = 2, \dots, n \\ r_{i2} = 0, i = 3, \dots, n \end{cases} \Rightarrow \begin{cases} \bar{r}_{i1} = 0, i = 3, \dots, n \\ \bar{r}_{i2} = 0, i = 3, \dots, n \end{cases}$$

deci coloana **1** se transformă în formă Hessenberg iar coloana **2** rămâne în formă superior triunghiulară.

La pasul **p** avem:

$$\left( R R_{12}^T(\theta_{12}) \cdots R_{p-1p}^T(\theta_{p-1p}) \right) R_{pp+1}^T(\theta_{pp+1}) = \tilde{R} R_{pp+1}^T(\theta_{pp+1}) = \bar{R} ,$$

$$\tilde{R} = R R_{12}^T(\theta_{12}) \cdots R_{p-1p}^T(\theta_{p-1p})$$

matricea  $\tilde{\mathbf{R}}$  are primele  $(p-1)$  coloane în formă Hessenberg iar restul coloanelor sunt în formă superior triunghiulară. Vom arata că la acest pas matricea  $\bar{\mathbf{R}}$  va avea primele  $p$  coloane în formă Hessenberg iar restul coloanelor în formă superior triunghiulară. Operația  $\bar{\mathbf{R}} := \tilde{\mathbf{R}} \mathbf{R}_{pp+1}^T(\theta_{pp+1})$  presupune doar schimbarea elementelor coloanelor  $p$  și  $p+1$ :

$$\begin{cases} \bar{\mathbf{r}}_{ip} = c\tilde{\mathbf{r}}_{ip} + s\tilde{\mathbf{r}}_{ip+1} , \forall i \\ \bar{\mathbf{r}}_{ip+1} = -s\tilde{\mathbf{r}}_{ip} + c\tilde{\mathbf{r}}_{ip+1} , \forall i \end{cases} + \begin{cases} \tilde{\mathbf{r}}_{ip} = 0, i = p+1, \dots, n \\ \tilde{\mathbf{r}}_{ip+1} = 0, i = p+2, \dots, n \end{cases} \Rightarrow$$

$$\begin{cases} \bar{\mathbf{r}}_{ip} = 0, i = p+2, \dots, n \\ \bar{\mathbf{r}}_{ip+1} = 0, i = p+2, \dots, n \end{cases}$$

Observăm din relația de mai sus că în matricea  $\bar{\mathbf{R}}$  coloana  $\mathbf{p}$  are formă Hessenberg iar coloana  $\mathbf{p}+1$  rămâne în formă superior triunghiulară (celelalte elemente din matrice nu se modifică).

Prin urmare după pasul  $\mathbf{n}-1$  matricea  $\bar{\mathbf{H}} = \mathbf{A}^{(k+1)}$  este în formă superioară Hessenberg. Algoritmul  $\mathbf{QR}$  de aproximare a valorilor proprii folosind descompunerea Givens păstrează forma Hessenberg.



## *Algoritmul QR pentru valori proprii*

// se aduce matricea  $A$  la forma Hessenberg

- $A = \bar{Q} A \bar{Q}^T$ ;
- $k = 0$ ;
- while (  $A \neq$  forma Schur reală )
  - $\left\{ \begin{array}{l} \bullet A = QR; // \text{ se calculează cu algoritmul Givens} \\ \bullet A = RQ \text{ sau } Q^T A Q; \\ \bullet k = k + 1; \end{array} \right.$

În practică se presupune că matricea  $A$  este în **formă Hessenberg neredusă**, adică:

$$a_{ii-1} \neq 0 \quad \forall i = 2, \dots, n$$

Dacă matricea nu este în formă neredusă, problema se decuplează:

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{matrix} p \\ n-p \end{matrix}, \quad p = n-1 \text{ sau } n-2$$

$p \quad n-p$

## Algoritmului $QR$ cu deplasare (“*shift*”) simplă

Algoritmul cu deplasare simplă este următorul:

- $A = \bar{Q} A \bar{Q}^T$ ; // aducerea la forma Hessenberg neredusă
- $k = 0$ ;
- while (  $A \neq$  forma Schur reală )
  - $\left\{ \begin{array}{l} \bullet A - d_k I_n = QR; // \text{ se calc. cu alg. Givens} \\ \bullet A := RQ + d_k I_n; \\ \bullet k = k + 1; \end{array} \right.$

$d_k \in \mathbb{R}$  sunt constantele de deplasare.

Dacă  $A - d I_n = QR$  ( $A^{(k)}$ ) și  $\bar{A} = RQ + d I_n$  ( $A^{(k+1)}$ ), se pune problema dacă cele două matrice sunt asemenea ( $A \sim \bar{A}$ ) (șirul de matrice construit cu pasul  $QR$  cu deplasare simplă au aceleași valori proprii).

$$\bar{A} = Q^T QRQ + d Q^T Q = Q^T (QR + d I_n) Q = Q^T A Q \Rightarrow \bar{A} \sim A$$

Varianta cu deplasare se efectuează pentru a accelera convergența algoritmului. Dacă  $\lambda_1, \lambda_2, \dots, \lambda_n$  sunt valorile proprii ale matricii  $A$  ordonate astfel ca:

$$|\lambda_1 - d| \geq |\lambda_2 - d| \geq \dots \geq |\lambda_n - d|$$

Rapiditatea cu care  $a_{p+1p}^{(k)} \rightarrow 0, k \rightarrow \infty$  este dată de rata de convergența a expresiei  $\left| \frac{\lambda_{p+1} - d}{\lambda_p - d} \right|^k$ . Dacă se alege  $d \approx \lambda_n$  convergența  $a_{n-1n}^{(k)} \rightarrow 0$  este rapidă. Avem următorul rezultat:

### **Teoremă**

Fie  $d$  o valoare proprie a unei matrice Hessenberg nereduse  $H$ . Dacă  $\overline{H} = RQ + d I_n$ , cu  $H - d I_n = QR$  descompunerea  $QR$  a matricei  $H - d I_n = QR$ . Atunci:

$$\overline{h}_{nn-1} = 0, \overline{h}_{nn} = d$$

Algoritmul **QR** cu deplasare simplă găsește valoarea proprie ***d*** într-un singur pas. Euristic s-a constatat că la fiecare pas, cea mai bună aproximare a unei valori proprii este  $\mathbf{a}_{nn}^{(k)}$ .

$$\mathbf{d}_k = \mathbf{a}_{nn}^{(k)}$$

### *Algoritmul QR cu deplasare simplă*

- $\mathbf{A} = \bar{\mathbf{Q}} \mathbf{A} \bar{\mathbf{Q}}^T$  ; // aducerea la forma Hessenberg neredusă
- $\mathbf{k} = \mathbf{0}$ ;
- while (  $\mathbf{A} \neq$  forma Schur reală )
  - $\mathbf{A} - \mathbf{a}_{nn} \mathbf{I}_n = \mathbf{QR}$ ; // se calc. cu algoritmul Givens
  - $\mathbf{A} := \mathbf{RQ} + \mathbf{a}_{nn} \mathbf{I}_n$ ;
  - $\mathbf{k} = \mathbf{k} + \mathbf{1}$ ;

## Algoritmului $QR$ cu deplasare (“*shift*”) dublă

În cazul când valorile proprii  $a_1, a_2$  corespunzătoare blocului:

$$G = \begin{bmatrix} a_{pp} & a_{pn} \\ a_{np} & a_{nn} \end{bmatrix}, \quad p = n - 1$$

sunt complexe,  $a_1, a_2 \in \mathbb{C}$ , abordarea cu deplasare simplă nu mai asigură accelerarea convergenței. Avem:

$$\begin{aligned}\det(\lambda I_2 - G) &= (\lambda - a_1)(\lambda - a_2) = (\lambda - a_{pp})(\lambda - a_{nn}) - a_{pn}a_{np} = \\ &= \lambda^2 - (a_1 + a_2)\lambda + a_1a_2 = \lambda^2 - (a_{pp} + a_{nn})\lambda + a_{pp}a_{nn} - a_{pn}a_{np}\end{aligned}$$

$$a_1 + a_2 = a_{pp} + a_{nn} = \text{trace}(G) \quad , \quad a_1a_2 = a_{pp}a_{nn} - a_{pn}a_{np} = \det G$$

Algoritmul **QR** cu deplasare dublă constă în trecerea de la matricea  $A = A^{(k)}$  la matricea  $A_2 = A^{(k+1)}$  realizând doi pași cu deplasare simplă :

$$A \rightarrow A_1 \text{ (deplasare simplă } a_1), A_1 \rightarrow A_2 \text{ (deplasare simplă } a_2)$$



$$A - a_1 I_n = Q_1 R_1$$

$$A_1 = R_1 Q_1 + a_1 I_n$$

$$A_1 - a_2 I_n = Q_2 R_2$$

$$A_2 = R_2 Q_2 + a_2 I_n$$

Fie matricea :

$$\begin{aligned} M &:= (Q_1 Q_2)(R_2 R_1) = Q_1 (Q_2 R_2) R_1 = Q_1 (A_1 - a_2 I_n) R_1 = \\ &= Q_1 (Q_1^T A Q_1 - a_2 I_n) R_1 = Q_1 Q_1^T A Q_1 R_1 - a_2 Q_1 R_1 = \\ &= (A - a_2 I_n) Q_1 R_1 = (A - a_2 I_n) (A - a_1 I_n) \\ M &= (Q_1 Q_2)(R_2 R_1) = (A - a_2 I_n) (A - a_1 I_n) = \\ &= A^2 - (a_1 + a_2)A + a_1 a_2 I_n \end{aligned}$$

Avem următoarele relații de asemănare:

$$A \sim A_1 = Q_1^T A Q_1 \sim A_2 = Q_2^T A_1 Q_2 = Q_2^T Q_1^T A Q_1 Q_2 = (Q_1 Q_2)^T A (Q_1 Q_2)$$

$$A_2 = (Q_1 Q_2)^T A (Q_1 Q_2) = Q^T A Q \quad , \quad Q := Q_1 Q_2$$

Matricea  $Q$  care asigură trecerea de la matricea  $A$  la matricea  $A_2$  este matricea ortogonală din descompunerea  $QR$  a matricii  $M = (A - a_2 I_n)(A - a_1 I_n)$ . Pasul  $QR$  cu deplasare dublă se face urmând etapele:

1) se calculează matricea  $M = A^2 - s A + qI_n$  cu

$$s = a_1 + a_2 = a_{pp} + a_{nn} \quad , \quad q = a_1 a_2 = a_{pp} a_{nn} - a_{pn} a_{np} ;$$

2) se calculează descompunerea  $QR$  a matricii  $M$ ;

3)  $A_2 := Q^T A Q$ .

## Vectori proprii

Considerăm două matrici asemenea  $A$  și  $B$ :

$$A \sim B \Leftrightarrow A = PBP^{-1}, \quad P \text{ matrice nesingulară}$$

Știm că cele două matrici au același polinom caracteristic,  $p_A(\lambda) \equiv p_B(\lambda)$ , deci au aceleași valori proprii. Ne interesează care este legătura între vectorii proprii asociați aceleiași valori proprii. Fie  $u$  vector propriu asociat valorii proprii  $\lambda$  pentru matricea  $A$  și  $w$  vector propriu asociat valorii proprii  $\lambda$  pentru matricea  $B$ . Care este relația între  $u$  și  $w$ ?

$$Au = \lambda u, Bw = \lambda w, A = PBP^{-1} \Rightarrow PBP^{-1}u = \lambda u \Rightarrow \\ BP^{-1}u = \lambda P^{-1}u \Rightarrow w = P^{-1}u, u = Pw$$

Dacă se aplică algoritmul **QR** unei matrici simetrice, forma Schur reală la care se ajunge este o matrice diagonală:

$$S = A = \mathbf{diag}[\lambda_1, \lambda_2, \dots, \lambda_n]$$

Legătura dintre matricea simetrică inițială  $A$  și matricea diagonală este de forma:

$$S = A = \mathbf{diag}[\lambda_1, \lambda_2, \dots, \lambda_n] = U^T A U$$

unde  $U$  este o matrice ortogonală, coloanele matricii  $U$  fiind vectori proprii asociați valorilor proprii reale  $\lambda_1, \lambda_2, \dots, \lambda_n$ . Matricea  $U$  se poate calcula astfel:

## *Algoritmul QR pentru matrici simetrice (valori +vectori proprii)*

// se aduce matricea  $A$  la forma Hessenberg

- $A = \bar{Q} A \bar{Q}^T$ ;

- $U = \bar{Q}^T$ ;

- $k = 0$ ;

- while (  $A \neq$  matrice diagonală )

- $A = QR$ ; // se calculează cu algoritmul Givens
  - $A = RQ$  sau  $Q^T A Q$ ;
  - $U = UQ$ ;
  - $k = k + 1$ ;

## Descompunerea după valori singulare (Singular Value Decomposition)

### Teoremă

Fie  $A \in \mathbb{R}^{m \times n}$ . Atunci există o matrice ortogonală pătratică de dimensiune  $m$ ,  $U \in \mathbb{R}^{m \times m}$ , o matrice ortogonală pătratică de dimensiune  $n$ ,  $V \in \mathbb{R}^{n \times n}$  și constantele pozitive:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \quad r \leq \min\{m, n\} \text{ a.î.}$$
$$A = U \Sigma V^T, \quad \Sigma \in \mathbb{R}^{m \times n}, \quad \Sigma = \begin{bmatrix} D & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}, \quad (1)$$
$$D \in \mathbb{R}^{r \times r}, \quad D = \text{diag}[\sigma_1, \dots, \sigma_r]$$

Constanta  $r$  este chiar rangul matricii  $A$ ,  $r = \text{rang}(A)$ .

Constantele  $\sigma_1, \sigma_2, \dots, \sigma_r$  poartă numele de *valori singulare* ale matricii  $A$ .

Folosind relația (1) avem:

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T,$$

$$AA^T = U\Sigma V^T V\Sigma^T U^T = U\Sigma\Sigma^T U^T = U\Lambda_m U^T,$$

$$\Lambda_m = \Sigma\Sigma^T = \begin{bmatrix} D^2 & \mathbf{0}_{r \times (m-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (m-r)} \end{bmatrix} \in \mathbb{R}^{m \times m}$$



$$A^T A = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T = V \Lambda_n V^T ,$$

$$\Lambda_n = \Sigma^T \Sigma = \begin{bmatrix} D^2 & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(n-r) \times r} & \mathbf{0}_{(n-r) \times (n-r)} \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Ținând cont de ortogonalitatea matricilor  $U$  și  $V$ , putem rescrie relațiile de mai sus astfel:

$$(AA^T)U = U \Lambda_m , \quad \Lambda_m = \text{diag}[\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, 0, \dots, 0] \in \mathbb{R}^{m \times m}$$

$$(A^T A)V = V \Lambda_n , \quad \Lambda_n = \text{diag}[\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, 0, \dots, 0] \in \mathbb{R}^{n \times n}$$

Din aceste relații deducem că  $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$  sunt valorile proprii strict pozitive ale matricilor  $AA^T$  și/sau  $A^T A$  iar matricile  $U$  și  $V$  sunt matrici ale căror coloane sunt vectorii proprii asociați (cei ce formează baze ortonormate). Matricile  $AA^T$  și  $A^T A$  sunt matrici simetrice:

$$\left( AA^T \right)^T = \left( A^T \right)^T A^T = AA^T \quad , \quad \left( A^T A \right)^T = A^T \left( A^T \right)^T = A^T A$$

și au toate valorile proprii nenegative:

$$\begin{aligned} (AA^T)u = \lambda u &\Rightarrow (AA^T u, u) = (\lambda u, u) \Rightarrow \\ \lambda &= \frac{(A^T u, A^T u)}{(u, u)} = \frac{\|A^T u\|_2^2}{\|u\|_2^2} \geq 0 \end{aligned}$$

Putem folosi descompunerea după valori singulare pentru a defini pseudo-inversa unei matrici oarecare  $A \in \mathbb{R}^{m \times n}$  ( $n \neq m$ ).

$$A = U\Sigma V^T, \quad A^{-1} =_{?} (U\Sigma V^T)^{-1} = (V^T)^{-1} \Sigma_{?}^{-1} U^{-1} = V \Sigma_{?}^{-1} U^T$$

Rămâne de definit matricea  $\Sigma_{?}^{-1}$ . Urmând acest raționament se definește *pseudoinversa Moore-Penrose* a unei matrici

$A \in \mathbb{R}^{m \times n}$  astfel:

$$A^I = V \Sigma^I U^T, \quad A^I \in \mathbb{R}^{n \times m}, \quad \Sigma^I = \begin{bmatrix} D^{-1} & 0_{r \times (m-r)} \\ \mathbf{0}_{(n-r) \times r} & 0_{(n-r) \times (m-r)} \end{bmatrix} \in \mathbb{R}^{n \times m},$$

$$D^{-1} \in \mathbb{R}^{r \times r}, \quad D^{-1} = \text{diag} \left[ \frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r} \right].$$

Pseudoinversa definită mai sus satisface următoarele proprietăți:

$$\begin{aligned} (A^I)^I &= A, \quad \forall A \in \mathbb{R}^{m \times n} ; & (A^T)^I &= (A^I)^T, \quad \forall A \in \mathbb{R}^{m \times n} \\ AA^I A &= A, & A^I A A^I &= A^I \end{aligned}$$

Există o proprietate care nu mai este satisfăcută de pseudoinversă deși este respectată de inversa clasică:

$$\exists A, B \text{ a.î. } (AB)^I \neq B^I A^I.$$

Descompunerea după valori singulare poate fi utilizată și pentru rezolvarea sistemelor liniare cu matrici oarecare ( $m \neq n$ )

$$Ax = b \quad , \quad A \in \mathbb{R}^{m \times n} \quad , \quad b \in \mathbb{R}^m \quad , \quad x := A^I b \in \mathbb{R}^n.$$

## Problema celor mai mici pătrate

$$A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m, \quad Ax = b, \quad x \in \mathbb{R}^n \quad (1)$$

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2$$

$$\vdots$$

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n = b_i$$

$$\vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m$$

Sistemul are soluții clasice dacă:

$$\text{rang } A = \text{rang } [A / b]$$

- $m < n$  - o infinitate de soluții
- $m \geq n$ 
  - dacă  $\text{rang } A = \text{rang } [A / b]$  soluții clasice
  - dacă  $\text{rang } A \neq \text{rang } [A / b]$  soluții în sensul celor mai mici pătrate

Vectorul reziduu:

$$r(x) = b - Ax \in \mathbb{R}^m$$

Vectorul  $x \in \mathbb{R}^n$  se numește *soluție în sensul celor mai mici pătrate* pentru sistemul (1) dacă este soluția următoarei probleme de optimizare:

$$\min\{\|r(x)\|_2^2 = \|b - Ax\|_2^2; x \in \mathbb{R}^n\} \quad (LSP)$$

$$A = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}, \quad b = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad m = 3, n = 2$$

$$\text{rang } A = 2 \neq \text{rang } [A / b] = 3$$



Sistemul:

$$\begin{aligned}x_1 + 4x_2 &= 0 \\ 2x_1 + 5x_2 &= 0 \\ 3x_1 + 6x_2 &= 1\end{aligned}\tag{2}$$

nu are soluție clasică (nu există  $x_1, x_2$  care să satisfacă toate cele 3 ecuații simultan). Vectorul reziduu are forma:

$$r(x) = b - Ax = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} - \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} -x_1 - 4x_2 \\ -2x_1 - 5x_2 \\ 1 - 3x_1 - 6x_2 \end{pmatrix}$$

Soluția în sensul celor mai mici pătrate a acestui sistem este definită ca soluția problemei de optimizare:

$$\min\{(-x_1 - 4x_2)^2 + (-2x_1 - 5x_2)^2 + (1 - 3x_1 - 6x_2)^2; x_1, x_2 \in \mathbb{R}\}$$

$$\min\{1 - 6x_1 - 12x_2 + 64x_1x_2 + 14x_1^2 + 77x_2^2; x_1, x_2 \in \mathbb{R}\}$$

Această problemă de minimizare are soluția:

$$x_1 = \frac{13}{18}, \quad x_2 = -\frac{2}{9}, \quad \|r(x)\|_2^2 = \frac{1}{6}$$

și este soluția în sensul celor mai mici pătrate a sistemului (2).

$$\text{range}(A) = \{ y \in \mathbb{R}^m; y = a_1 A^1 + a_2 A^2 + \cdots + a_n A^n, a_i \in \mathbb{R}, i = 1, n \}$$

$$A = \begin{bmatrix} A^1 & A^2 & \cdots & A^n \end{bmatrix}, A^i \in \mathbb{R}^m \text{ sunt coloanele matricii } A$$

## Teoremă

Fie  $A \in \mathbb{R}^{m \times n}$  ( $m \geq n$ ),  $b \in \mathbb{R}^m$ . Un vector  $x \in \mathbb{R}^n$  minimizează norma euclidiană a vectorului reziduu  $\|r(x)\|_2 = \|b - Ax\|_2$ , rezolvând problema (*LSP*), dacă și numai dacă:

$$r(x) \perp \text{range}(A) \quad \Leftrightarrow \quad A^T r(x) = 0$$

sau echivalent

$$A^T A x = A^T b \quad (3)$$

Sistemul (3) poartă numele de sistemul de *ecuații normale*.

Este un sistem pătratic de dimensiune  $n$ , matricea sistemului  $A^T A \in \mathbb{R}^{n \times n}$  este simetrică. Sistemul de ecuații normale (3) este nesingular dacă și numai dacă  $\text{rang} A = n$ , în acest caz soluția  $\mathbf{x}$  a sistemului (3) este unică.

$$\det A^T A \neq 0 \Leftrightarrow \text{rang} A = n$$

$$A = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}, \quad A^T A = \begin{bmatrix} 14 & 32 \\ 32 & 77 \end{bmatrix}, \quad A^T b = \begin{pmatrix} 3 \\ 6 \end{pmatrix}$$

$$\begin{aligned} 14x_1 + 32x_2 &= 3 \\ 32x_1 + 77x_2 &= 6 \end{aligned} \Rightarrow x_1 = \frac{13}{18}, \quad x_2 = -\frac{2}{9}$$

## Pseudo-inversa matricii $A$

Presupunem că  $A$  are **rang**  $A = n$ . Atunci pseudo-inversa poate fi definită ca:

$$A^+ = \left( A^T A \right)^{-1} A^T \in \mathbb{R}^{n \times m} \quad (A^+ = A^I \quad ?)$$

$$A^+ = \begin{bmatrix} 14 & 32 \\ 32 & 77 \end{bmatrix}^{-1} * \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

## Rezolvarea sistemului de ecuații normale

- 1) Folosind factorizarea Cholesky (descompunere  $LU$ ) pentru matrici simetrice:

$$A^T A = LL^T, \quad L \in \mathbb{R}^{n \times n} \text{ matrice inferior triunghiulară}$$

- Se calculează matricea  $A^T A$  și vectorul  $A^T b$ ;
  - Se calculează factorizarea Cholesky a matricii  $A^T A = LL^T$ ;
  - Se rezolvă sistemul inferior triunghiular  $Ly = A^T b$  pentru  $y$ ;
  - Se rezolvă sistemul superior triunghiular  $L^T x = y$  pentru  $x$ ;
- 2) Se calculează descompunerea  $QR$  (cu algoritmul lui

Householder adaptat) pentru matricea  $A$ :

$$A = QR, \quad Q \in \mathbb{R}^{m \times m} \text{ matrice ortogonală, } R \in \mathbb{R}^{m \times n},$$

$$R = \begin{bmatrix} \bar{R} \in \mathbb{R}^{n \times n} \\ \mathbf{0}_{(m-n) \times n} \end{bmatrix}, \quad \bar{R} - \text{matrice superior triunghiulară}$$

- Se calculează factorizarea  $QR$  modificată a matricii  $A$ ;
- Se calculează vectorul  $Q^T b$  ;
- Se rezolvă sistemul sup. triunghiular  $\bar{R}x = (Q^T b)_{i=1,n}$  ;



3) Se folosește desc. după valori singulare a matricii  $A$

$$A = U\Sigma V^T, \quad \Sigma \in \mathbb{R}^{m \times n}, \quad U \in \mathbb{R}^{m \times m}, \quad V \in \mathbb{R}^{n \times n}$$

- Se calculează SVD pentru matricea  $A=U\Sigma V^T$ ;
- Se calculează vectorul  $U^T b$ ;
- Se rezolvă sistemul diagonal  $\Sigma w = U^T b$  pentru  $w$ ;
- Soluția este  $x=Vw$ ;

1), 2) sau 3) ?  $\rightarrow$  se recomandă 2)